

TRƯỜNG CAO ĐẲNG FPT POLYTECHNIC



FPT POLYTECHNIC

BÁO CÁO DỰ ÁN TỐT NGHIỆP

**ĐỀ TÀI: Báo cáo phân tích thị trường bất động sản
NEW YORK Giai đoạn 2025 - 2026 - DP02**

Giảng viên hướng dẫn : Nguyễn Quy Tôn

Chuyên ngành : Xử lý dữ liệu

Nhóm Thực hiện : DP-02

Sinh viên thực hiện :

Phạm Trung Kiên	PH61391
Nguyễn Hữu Duy	PH58633
Trần Thanh Nghị	PH50154
Trần Văn Thanh	PH50084
Ngô Quốc Huy	PH48295

Hà Nội - 2026

MỤC LỤC

1. GIỚI THIỆU VỀ DỰ ÁN	6
1.1 Giới thiệu	6
1.2 Bối cảnh thực hiện	7
1.3 Mục tiêu của dự án	8
1.3.1 Mục tiêu tổng quát	8
1.3.2 Mục tiêu cụ thể	8
1.4 Phạm vi của dự án	8
1.5 Công nghệ sử dụng	9
1.6 Quy trình thực hiện dự án	10
1.7 Ý nghĩa của dự án	11
1.7.1 Ý nghĩa thực tiễn	11
1.7.2 Ý nghĩa học thuật và Năng lực chuyên môn	11
1.7.3 Kế hoạch thực hiện dự án	11
2. PHÂN TÍCH YÊU CẦU KHÁCH HÀNG	13
2.1 Giới thiệu	13
2.2 Bài toán đặt ra	13
2.3 Đối tượng sử dụng	14
2.3.1 Nhà đầu tư bất động sản	14
2.3.2 Nhà phân tích dữ liệu	14
2.3.3 Người học và giảng viên	15
2.4 Các yêu cầu của khách hàng	15
2.5 Các câu hỏi cần giải quyết	15
2.6 Các chỉ số cần theo dõi	16
2.7 Yêu cầu về trực quan hóa dữ liệu	16
2.8 Yêu cầu về hệ thống Dashboard	17
2.9 Quy trình thực hiện dự án	18
3. LÀM SẠCH VÀ CHUYỂN ĐỔI DỮ LIỆU	18
3.1 Giới thiệu	18
3.2 Mục tiêu của quá trình làm sạch dữ liệu	18
3.3 Quy trình làm sạch dữ liệu	19
3.4 Đọc dữ liệu bằng Pandas	19
3.5 Kiểm tra cấu trúc dữ liệu	20
3.6 Kiểm tra giá trị thiếu (Missing Values)	20
3.7 Kiểm tra dữ liệu trùng lặp	21
3.8 Chuẩn hóa kiểu dữ liệu	21

3.9 Chuyển đổi dữ liệu	21
3.10 Kiểm tra dữ liệu sau xử lý	22
3.11 Xuất dữ liệu đã làm sạch	22
4. XỬ LÝ DỮ LIỆU	23
4.1 Giới thiệu	23
4.2 Mục tiêu của quá trình xử lý dữ liệu	23
4.3 Quy trình xử lý dữ liệu	24
4.4 Khảo sát tổng quan dữ liệu	25
4.5 Thống kê mô tả	26
4.6 Nhóm dữ liệu (Grouping Data)	27
4.7 Tính toán các chỉ số KPI	28
4.8 Chuẩn bị dữ liệu cho trực quan hóa	29
4.9 Bổ sung phần kỹ thuật chuyên sâu	29
4.9.1 Mã nguồn Python/Pandas thực hiện toàn bộ quy trình tiền xử lý	29
4.9.2 Lý thuyết Mô hình hóa dữ liệu (Data Modeling)	35
4.10 Chuẩn bị dữ liệu cho Dashboard Streamlit	35
5. TRỰC QUAN HÓA DỮ LIỆU	36
5.1 Giới thiệu	36
5.2 Mục đích của trực quan hóa dữ liệu	37
5.3 Lựa chọn thư viện trực quan hóa	38
5.4 Hệ thống chỉ số KPI	38
5.5 Biểu đồ số lượng giao dịch theo quận	39
5.6 Biểu đồ giá bán theo quận	40
5.7 Biểu đồ phân phối giá bán theo quận	41
5.8 Biểu đồ xu hướng giao dịch theo thời gian	42
5.9 Biểu đồ tỷ lệ loại hình bất động sản	43
5.10 Biểu đồ bản đồ nhiệt không gian	44
5.11 Phân phối giá bán nhà theo Quận	45
5.12 Biểu đồ Top 15 khu vực có nhiều giao dịch nhất	46
5.13 Top 15 khu vực có giá bán trên mỗi sqft cao nhất	48
5.14 Biểu đồ xếp hạng mức độ tương quan các yếu tố với giá bán	49
5.15 Ma trận tương quan giữa các yếu tố và Giá bán	50
5.16 Giá trung vị bất động sản theo nhóm tuổi công trình	52
5.17 Biểu đồ so sánh mặt bằng giá nhà theo thu nhập bình quân khu vực	53
5.18 Tương quan giữa Diện tích sử dụng (sqft) và Giá bán trung vị (\$)	54
5.19 Tìm kiếm bất động sản tương đồng theo tiêu chí	55
5.19 Bộ lọc dữ liệu	56
5.20 Lợi ích và giá trị cốt lõi của hệ thống web dashboard	58

6. Xây dựng báo cáo	58
6.1 Kiến trúc giao diện Báo cáo	58
6.2.1 Dashboard	59
7. Kết luận	65
7.1 Tổng hợp báo cáo	65
7.2 Khó khăn	65
7.3 Thuận lợi	66
7.4 Hướng phát triển	67
7.4.1 Mục tiêu chung	67
7.4.2 Các hướng phát triển	67
7.4.2.1. Dự báo xu hướng giá bất động sản theo chuỗi thời gian (Time-series)	67
7.4.2.2. Phân tích tác động của tiện ích	67
7.4.2.3. Phân tích không gian chuyên sâu	67
7.4.2.4. Phân tích xu hướng thị trường	67
7.4.2.5. Mở rộng dữ liệu	67
7.4.2.6. Phát triển Dashboard	68
7.4.2.7. Ứng dụng AI để ra quyết định (Prescriptive & AutoML)	68

MỤC LỤC ẢNH

Hình 1: Sơ đồ quy trình xử lý dữ liệu tổng thể (Data Processing Pipeline)	24
Hình 2: Đọc và chuẩn hóa cấu trúc cột	31
Hình 3: Kiểm tra & xử lý MISSING VALUES, DUPLICATES	32
Hình 4: Xử lý ngoại lai và gán cờ nghiệp vụ	33
Hình 5: FEATURE ENGINEERING chuyên sâu	34
Hình 6: Sơ đồ Kho dữ liệu theo mô hình Starflake Schema	36
Hình 7: Hệ thống chỉ số KPI	39
Hình 8: Biểu đồ số lượng giao dịch theo quận	40
Hình 9: Biểu đồ giá trung vị theo khu vực	41
Hình 10: Box plot phân phối giá bán	42
Hình 11: Biểu đồ phân khúc khách hàng	43
Hình 12: Biểu đồ tỷ lệ loại hình bất động sản	44
Hình 13: Density Heatmap bản đồ không gian	45
Hình 14: Phân phối giá bán nhà theo Quận	46
Hình 15: Top 15 khu vực có nhiều giao dịch nhất	47
Hình 16: Top 15 khu vực có giá bán trên mỗi sqft cao nhất (trung vị)	49
Hình 17: Xếp hạng mức độ tương quan Pearson với Giá bán	50
Hình 18: Ma trận tương quan giữa các yếu tố và Giá bán	52
Hình 19: Giá trung vị bất động sản phân theo Nhóm Tuổi công trình	53
Hình 20: Mặt bằng Giá nhà Trung vị xếp theo Mức Thu nhập Bình quân Khu vực (\$)	54
Hình 21: Tương quan giữa Diện tích sử dụng (sqft) và Giá bán trung vị (\$)	55
Hình 14: Bộ lọc dữ liệu	57
Hình 15: Tab Tổng Quan — Các chỉ số KPI và biểu đồ phân tích theo Borough	60
Hình 16: Tab Phân Tích Khu Vực — Bản đồ Nhiệt Hotspot NYC	61
Hình 17: Tab Yếu Tố Quyết Định Giá — Bảng tóm tắt và xếp hạng tương quan Pearson	62
Hình 18: Tab Dự Báo & Mô Hình ML — Bảng so sánh hiệu năng giữa 2 thuật toán	63
Hình 19: Tab Tra Cứu BĐS & Tiện Ích — Biểu đồ tỷ trọng đóng góp của tiện ích vào định giá (2025–2026)	64

MỤC LỤC BẢNG

Bảng 1: Kế hoạch dự án	13
Bảng 2: Phân loại nhóm thuộc tính dữ liệu thô	26
Bảng 3: Bảng thống kê mô tả chi tiết tập dữ liệu (47,039 bản ghi sạch):	27
Bảng 4: Thống kê khối lượng và giá trị giao dịch bất động sản theo từng quận	28
Bảng 5: Bảng tóm tắt quy trình Pipeline tiền xử lý dữ liệu	31

1. GIỚI THIỆU VỀ DỰ ÁN

1.1 Giới thiệu

Trong bối cảnh chuyển đổi số diễn ra mạnh mẽ trên toàn cầu, dữ liệu đã trở thành nguồn tài nguyên quan trọng giúp doanh nghiệp và tổ chức đưa ra các quyết định chính xác, kịp thời và có cơ sở khoa học. Thay vì dựa vào kinh nghiệm hoặc cảm tính, các quyết định hiện nay ngày càng được xây dựng dựa trên quá trình thu thập, xử lý và phân tích dữ liệu thực nghiệm.

Lĩnh vực bất động sản là một trong những ngành có khối lượng dữ liệu khổng lồ, đa biến và liên tục thay đổi theo thời gian. Mỗi giao dịch mua bán đều tạo ra nhiều thông tin giá trị như vị trí địa lý, loại hình bất động sản, giá bán, tổng diện tích sử dụng, tuổi đời công trình, thời điểm giao dịch và các tiện ích hạ tầng liên quan. Nếu được khai thác đúng cách, nguồn dữ liệu này không chỉ phản ánh bức tranh toàn cảnh về cung - cầu và xu hướng biến động giá của thị trường, mà còn là kim chỉ nam giúp các nhà đầu tư cá nhân, tổ chức tài chính tối ưu hóa danh mục giải ngân nguồn vốn và giảm thiểu tối đa rủi ro chôn vốn.

Đặc biệt, thị trường bất động sản tại Thành phố New York (New York City – NYC, Mỹ) luôn được đánh giá là một trong những thị trường sôi động, phức tạp và có giá trị tỷ suất lợi nhuận thu hút bậc nhất thế giới. Với sự dịch chuyển liên tục về hạ tầng giao thông, quy hoạch đô thị và mật độ tiện ích công cộng (như khoảng cách đến ga tàu điện ngầm, bệnh viện, trường học, công viên), việc định giá bất động sản tại New York chịu sự chi phối của hàng loạt biến số phi tuyến tính phức tạp.

Xuất phát từ nhu cầu thực tiễn đó, dự án **"Báo cáo phân tích thị trường bất động sản New York giai đoạn 2025 – 2026"** được xây dựng nhằm thiết lập một hệ thống phân tích dữ liệu toàn diện. Toàn bộ quy trình được xây dựng khép kín: từ bước thu thập dữ liệu giao dịch thô, tiền xử lý, làm giàu dữ liệu không gian (Spatial Enrichment), tổ chức Kho dữ liệu (Data Warehouse) theo mô hình Star-Schema, cho đến việc ứng dụng thuật toán Học máy (Machine Learning) như CatBoost Regressor và Random Forest Regressor để đo lường mức độ ảnh hưởng của các tiện ích cốt lõi và đề xuất dự đoán mục đích phân tích mà nhóm đặt ra. Sản phẩm đầu ra cuối cùng được trực quan hóa và triển khai dưới dạng một ứng dụng Web Dashboard tương tác hiện đại thông qua framework Streamlit và thư viện Plotly.

Khác với việc chỉ tạo ra các bảng thống kê hay biểu đồ mô tả đơn lẻ, dự án hướng đến việc mô phỏng đầy đủ vòng đời thực tế của một dự án Khoa học Dữ

liệu (Data Science / Data Analytics Lifecycle). Qua đó, dự án cung cấp các góc nhìn phân tích định lượng thực tế, hỗ trợ phân loại hai nhóm chiến lược đầu tư chuyên biệt (Tích sản bền vững và Đầu cơ lướt sóng), đồng thời giúp nhóm thực hiện nâng cao năng lực tư duy kỹ thuật và xử lý dữ liệu trong môi trường doanh nghiệp.

1.2 Bối cảnh thực hiện

Sự phát triển của công nghệ thông tin và chính sách dữ liệu mở đã tạo điều kiện cho nhiều cơ quan quản lý đô thị công bố dữ liệu công khai, giúp người phân tích có thể tiếp cận nguồn tài nguyên phong phú phục vụ nghiên cứu. Trong số đó, dữ liệu giao dịch bất động sản từ Cổng dữ liệu mở Thành phố New York (NYC Open Data) là một nguồn dữ liệu có giá trị cao bởi quy mô lớn, tính minh bạch và phản ánh chân thực đặc điểm của một siêu đô thị hàng đầu thế giới.

Tuy nhiên, dữ liệu thô thu thập được từ thực tế thường chứa đựng nhiều rào cản kỹ thuật phức tạp:

- Thiếu hụt thông tin không gian: Tập dữ liệu gốc chỉ cung cấp địa chỉ nhà dưới dạng văn bản (text) mà không có tọa độ địa lý (Kinh độ, Vĩ độ), khiến việc phân tích mật độ và tính toán khoảng cách đến các cơ sở hạ tầng công cộng gặp nhiều trở ngại.

- Nhiều dữ liệu và giá trị ngoại lệ (Outliers): Tồn tại một lượng lớn các bản ghi giao dịch chuyển nhượng nội bộ giữa các thành viên trong gia đình hoặc thừa kế với giá trị danh nghĩa (0 USD hoặc 10 USD), cùng với các giao dịch tòa nhà thương mại quy mô hàng tỷ USD làm sai lệch nghiêm trọng phân phối giá chuẩn của thị trường.

- Dữ liệu khuyết thiếu và sai lệch định dạng: Tình trạng thiếu hụt dữ liệu ở các cột diện tích sàn sử dụng, năm xây dựng, cũng như sự không đồng nhất về kiểu dữ liệu và quy chuẩn tên gọi giữa các quận (Borough), khu phố (Neighborhood).

Bên cạnh đó, việc quan sát dữ liệu dưới dạng bảng tính phẳng truyền thống với hàng chục nghìn dòng dữ liệu khiến người dùng không thể nhận diện được các quy luật ẩn sâu, mối tương quan giữa tiện ích với giá bán, hay chu kỳ tăng trưởng của dòng tiền. Vì vậy, việc xây dựng một đường ống dữ liệu (Data Pipeline) tự động để làm sạch, mô hình hóa kho dữ liệu và chuyển đổi thành hệ thống Dashboard trực quan tương tác là yêu cầu cấp thiết nhằm hỗ trợ quá trình ra quyết định đầu tư nhanh chóng và chính xác.

1.3 Mục tiêu của dự án

1.3.1 Mục tiêu tổng quát

Xây dựng một hệ thống phân tích dữ liệu bất động sản toàn diện cho Thành phố New York giai đoạn 2025–2026 bằng ngôn ngữ lập trình Python, kết hợp kiến trúc Kho dữ liệu chuẩn hóa và giao diện Web Dashboard tương tác Streamlit, giúp người dùng khai thác sâu các insight giá trị, theo dõi các chỉ số thị trường và tối ưu hóa quyết định đầu tư dựa trên dữ liệu.

1.3.2 Mục tiêu cụ thể

Để hiện thực hóa mục tiêu tổng quát, dự án tập trung vào 3 nhóm mục tiêu cốt lõi sau:

1. Phân tích yếu tố cấu thành giá bất động sản: Ứng dụng mô hình Học máy (Machine Learning) CatBoost Regressor để dự báo và định giá Bất động sản, Random Forest Regressor để phân tích tác động của tiện ích không gian.
2. Đo lường rủi ro và tiềm năng sinh lời: Tính toán tốc độ tăng trưởng kép (CAGR) qua chu kỳ 19 tháng (2025–2026), đo lường độ biến động giá giữa 5 quận và chấm Điểm Tin Cây (Confidence Score) cho từng khu vực.
3. Mục tiêu xây dựng mô hình: Xây dựng hệ thống học máy giúp tự động hóa việc thẩm định giá bán bất động sản tại New York và dự báo xu hướng biến động giá trong các mốc thời gian tương lai (+1 tháng, +6 tháng, +12 tháng).
4. Trực quan hóa và xây dựng Web Dashboard tương tác: Xây dựng các bộ lọc giúp người dùng dễ dàng định hướng chiến lược đầu tư, sàng lọc BĐS theo đúng ngân sách và nhu cầu sống và kiểm tra xem căn nhà mình mua có bị “hớ” giá không.

1.4 Phạm vi của dự án

Dự án tập trung nghiên cứu và phân tích thị trường bất động sản tại Thành phố New York (NYC) dựa trên tập dữ liệu giao dịch công khai kết hợp dữ liệu không gian, với các phạm vi cụ thể sau:

- Phạm vi không gian & thời gian: Phân tích dữ liệu giao dịch tại 5 quận chính của New York (Manhattan, Brooklyn, Queens, Bronx, Staten Island) trong giai đoạn 2025 – 2026.

- Các nội dung chính thực hiện:

- + Thu thập dữ liệu giao dịch và cào dữ liệu tiện ích không gian (OpenStreetMap).
 - + Làm sạch và tiền xử lý dữ liệu (loại bỏ outliers, xử lý missing values, chuẩn hóa kiểu dữ liệu).
 - + Mô hình hóa Kho dữ liệu theo kiến trúc Starflake Schema (kết hợp giữa mô hình Sao và Bông tuyết để quản lý phân cấp danh mục).
 - + Khám phá dữ liệu (EDA), phân tích biến động giá và tốc độ tăng trưởng kép (CAGR).
 - + Ứng dụng mô hình CatBoost Regressor để định giá và dự báo xu hướng BĐS tương lai.
 - + Ứng dụng mô hình Học máy cơ bản (Random Forest Regressor) để định lượng mức độ tác động của các tiện ích xung quanh (Feature Importance) lên giá nhà.
 - + Xây dựng Web Dashboard trực quan tương tác bằng Streamlit.
- Giới hạn đề tài: Dự án ứng dụng Machine Learning để đánh giá tầm quan trọng của đặc trưng tiện ích và hỗ trợ định giá, không mở rộng sang các mô hình dự báo chuỗi thời gian hay mạng nơ-ron Deep Learning phức tạp.

1.5 Công nghệ sử dụng

Để xây dựng hệ thống hoàn chỉnh, dự án sử dụng các công nghệ và thư viện chính sau:

- Python 3.10+: Ngôn ngữ lập trình cốt lõi cho toàn bộ pipeline từ xử lý dữ liệu đến triển khai ứng dụng web.
- Pandas & NumPy: Đọc, làm sạch, lọc, tổng hợp DataFrame và hỗ trợ tính toán ma trận số học hiệu năng cao.
- SciPy (thuật toán cKDTree): Tối ưu hóa tính toán ma trận khoảng cách không gian từ bất động sản đến các tiện ích công cộng.
- SQLite (nyc_warehouse.db) & PostgreSQL: Hệ quản trị cơ sở dữ liệu lưu trữ Kho dữ liệu theo kiến trúc Starflake Schema.
- SQLAlchemy & psycopg2-binary: Thư viện ORM định nghĩa Schema, quản lý kết nối và nạp dữ liệu vào Database.
- Scikit-learn: Huấn luyện mô hình RandomForestRegressor và trích xuất tỷ trọng đóng góp của đặc trưng (Feature Importance).

- Streamlit & Plotly Express: Framework xây dựng Web Dashboard tương tác và vẽ hệ thống biểu đồ động đa chiều.
- Visual Studio Code, Git & GitHub: Môi trường lập trình và quản lý phiên bản mã nguồn.
- CatBoost (CatBoostRegressor): Thư viện Gradient Boosting chuyên dụng để huấn luyện mô hình dự báo giá bán và thẩm định giá bất động sản tương tác.
- PyDeck & GeoPandas: Thư viện xử lý dữ liệu không gian địa lý (GeoJSON) và dựng bản đồ nhiệt 3D/2D tương tác WebGL trên Dashboard.
- OpenStreetMap (OSM) API: Nguồn dữ liệu bản đồ mở dùng để trích xuất hơn 51.000 tọa độ tiện ích công cộng (Ga tàu, Bệnh viện, Trường học, Công viên).
- Jupyter Notebook (.ipynb): Môi trường thực nghiệm, xử lý dữ liệu khám phá (EDA) và huấn luyện mô hình Machine Learning trước khi đóng gói lên ứng dụng.
- Statsmodels: Hỗ trợ tính toán đường xu hướng hồi quy (OLS Trendline) và đo lường hệ số xác định trên các biểu đồ phân tán.

1.6 Quy trình thực hiện dự án

Quá trình thực hiện dự án được triển khai tuần tự qua 7 bước theo đường ống dữ liệu (Data Pipeline) khép kín:

1. Thu thập dữ liệu: Thu thập dữ liệu giao dịch bất động sản New York (nyc_sales.csv) và dữ liệu tọa độ tiện ích công cộng (bến tàu, bệnh viện, trường học, công viên) từ OpenStreetMap.
2. Làm sạch & Tiền xử lý (preprocess.py): Rà soát dữ liệu, xử lý giá trị khuyết thiếu, loại bỏ giao dịch bất thường (giá 0 USD hoặc diện tích bằng 0) và chuẩn hóa kiểu dữ liệu.
3. Làm giàu dữ liệu không gian & ETL (etl_to_postgres.py / etl_to_sqlite.py): Ứng dụng thuật toán cKDTree để tính toán khoảng cách tiện ích, sau đó phân tách dữ liệu thành bảng Sự kiện (Fact_Sales) và các bảng Chiều (Dim_Location, Dim_Property, Dim_Amenities) nạp vào Kho dữ liệu theo kiến trúc Starflake Schema.

4. Phân tích khám phá dữ liệu (EDA): Tính toán thống kê mô tả, phân tích tương quan giữa các biến số, đo lường tốc độ tăng trưởng CAGR và tỷ lệ phân bố theo từng quận.
5. Triển khai thuật toán CatBoost Regressor (kết hợp Linear/Ridge Regression làm mô hình đối chuẩn cơ sở) để tự động thẩm định giá và dự báo xu hướng giá tương lai (1 đến trên 12 tháng); đồng thời sử dụng Random Forest Regressor để định lượng tỷ trọng đóng góp của các tiện ích không gian vào giá trị bất động sản.
6. Thiết kế Web Dashboard (app.py, src/dashboard.py): Xây dựng giao diện trực quan trên Streamlit với hệ thống bộ lọc động đa chiều và bản đồ nhiệt.
7. Đánh giá & Hoàn thiện báo cáo: Rút ra các insight kinh doanh thực tiễn, phân loại chiến lược đầu tư (Tích sản vs Lướt sóng) và tổng kết tài liệu báo cáo.

1.7 Ý nghĩa của dự án

1.7.1 Ý nghĩa thực tiễn

Đối với nhà đầu tư và người mua nhà: Cung cấp công cụ định lượng thị trường minh bạch, giúp nhận diện các khu vực tiềm năng, theo dõi tốc độ tăng trưởng giá và lựa chọn chiến lược đầu tư (dài hạn hoặc ngắn hạn) phù hợp với nguồn vốn.

Đối với môi giới và phân tích thị trường: Rút ngắn thời gian khảo sát thực địa thông qua bản đồ không gian và các chỉ số định lượng (CAGR, Điểm Tin Cậy), nâng cao hiệu quả tư vấn khách hàng.

1.7.2 Ý nghĩa học thuật và Năng lực chuyên môn

Dự án giúp nhóm thực hành và hoàn thiện toàn bộ chu trình làm việc thực tế của một Data Analyst / Data Engineer: từ kỹ thuật xử lý dữ liệu lớn bằng Python, thiết kế Kho dữ liệu Starflake Schema, ứng dụng Machine Learning giải quyết bài toán kinh doanh, đến việc tự tay lập trình và triển khai ứng dụng Web Dashboard tương tác.

1.7.3 Kế hoạch thực hiện dự án

Để đảm bảo tiến độ và chất lượng của đồ án, nhóm đã phân bổ chi tiết các hạng mục công việc trong suốt thời gian thực hiện như sau:

Bảng 1: Kế hoạch dự án

TT	Hạng mục	Bắt đầu	Kết thúc	Kết quả	Thành viên
1	Giới thiệu dự án	16/04/2026	28/04/2026	Hoàn thành	Cả nhóm
1.1	Giới thiệu	16/04/2026	28/04/2026	Hoàn thành	Cả nhóm
1.2	Yêu cầu	16/04/2026	28/04/2026	Hoàn thành	Cả nhóm
1.3	Lập kế hoạch dự án	16/04/2026	28/04/2026	Hoàn thành	Kiên
2	Phân tích yêu cầu	29/04/2026	18/05/2026	Hoàn thành	Kiên
2.1	Phân tích yêu cầu KH	29/04/2026	05/05/2026	Hoàn thành	Kiên
2.2	Câu chuyện dữ liệu	29/04/2026	08/05/2026	Hoàn thành	Nghị
2.3	Kiến trúc hệ thống	06/05/2026	18/05/2026	Hoàn thành	Huy, Duy
2.4	Giải thích về bộ dữ liệu khách hàng	06/05/2026	18/05/2026	Hoàn thành	Huy, Duy
3	Làm sạch và chuyển đổi dữ liệu	19/05/2026	12/06/2026	Hoàn thành	Kiên
3.1	Chuẩn bị dữ liệu	19/05/2026	26/05/2026	Hoàn thành	Kiên
3.2	Làm sạch dữ liệu	27/05/2026	04/06/2026	Hoàn thành	Kiên
3.3	Chuyển đổi dữ liệu	05/06/2026	12/06/2026	Hoàn thành	Kiên
4	Xử lý dữ liệu	13/06/2026	05/07/2026	Hoàn thành	Kiên
4.1	Chuẩn hóa dữ liệu	13/06/2026	20/06/2026	Hoàn thành	Duy
4.2	Mô hình hóa dữ liệu	21/06/2026	28/06/2026	Hoàn thành	Huy, Duy
4.3	Xử lý dữ liệu & Tính toán chỉ số	29/06/2026	05/07/2026	Hoàn thành	Huy
5	Trực quan hóa dữ liệu	06/07/2026	22/07/2026	Hoàn thành	Huy, Kiên
5.1	Các kỹ thuật trực quan hóa	06/07/2026	22/07/2026	Hoàn thành	Huy, Kiên
6	Xây dựng báo cáo	23/07/2026	08/08/2026	Hoàn thành	Nghị, Huy

6.1	Dashboard và Report	23/07/2026	08/08/2026	Hoàn thành	Cả nhóm
6.2	Xây dựng báo cáo	23/07/2026	08/08/2026	Hoàn thành	Cả nhóm
7	Kết luận	09/08/2026	18/08/2026	Hoàn thành	Cả nhóm
7.1	Báo cáo	09/08/2026	18/08/2026	Hoàn thành	Cả nhóm
7.2	Khó khăn	09/08/2026	18/08/2026	Hoàn thành	Cả nhóm
7.3	Thuận lợi	09/08/2026	18/08/2026	Hoàn thành	Cả nhóm
7.4	Hướng phát triển	09/08/2026	18/08/2026	Hoàn thành	Cả nhóm

2. PHÂN TÍCH YÊU CẦU KHÁCH HÀNG

2.1 Giới thiệu

Trong một dự án phân tích dữ liệu, việc hiểu đúng yêu cầu của khách hàng là bước đầu tiên và cũng là bước quan trọng nhất. Một Dashboard chỉ thực sự có giá trị khi nó trả lời được những câu hỏi mà người sử dụng quan tâm. Nếu không xác định rõ mục tiêu ngay từ đầu, quá trình phân tích có thể đi sai hướng, dẫn đến việc xây dựng nhiều biểu đồ không cần thiết hoặc bỏ sót những thông tin quan trọng.

Đối với dự án BÁO CÁO PHÂN TÍCH THỊ TRƯỜNG BẤT ĐỘNG SẢN NEW YORK GIAI ĐOẠN 2025 - 2026, mục tiêu không chỉ dừng lại ở việc trực quan hóa dữ liệu mà còn giúp người dùng khai thác các thông tin có giá trị từ bộ dữ liệu giao dịch bất động sản thành phố New York. Vì vậy, trước khi tiến hành xử lý dữ liệu, cần xác định rõ đối tượng sử dụng, nhu cầu phân tích và các chỉ số cần theo dõi trên Dashboard.

2.2 Bài toán đặt ra

Bộ dữ liệu giao dịch bất động sản của thành phố New York chứa hàng nghìn bản ghi với nhiều trường thông tin khác nhau như vị trí, giá bán, diện tích, loại hình bất động sản, thời gian giao dịch và các thuộc tính liên quan.

Khi dữ liệu được lưu dưới dạng bảng, người dùng gặp nhiều khó khăn trong việc:

- Quan sát xu hướng biến động của thị trường.
- So sánh giá bán giữa các khu vực.
- Xác định khu vực có nhiều giao dịch.
- Phân tích loại hình bất động sản phổ biến.
- Đánh giá sự phân bố của giá bán.
- Theo dõi sự thay đổi của thị trường theo thời gian.

Nếu phải thực hiện các phép tính thủ công trên hàng nghìn dòng dữ liệu, quá trình phân tích sẽ mất nhiều thời gian và dễ xảy ra sai sót. Do đó, cần xây dựng một hệ thống Dashboard có khả năng tổng hợp dữ liệu, trực quan hóa kết quả và hỗ trợ người dùng khai thác thông tin nhanh chóng.

2.3 Đối tượng sử dụng

Dashboard được xây dựng hướng đến nhiều nhóm người dùng khác nhau, mỗi nhóm có mục tiêu khai thác dữ liệu riêng.

2.3.1 Nhà đầu tư bất động sản

Đây là nhóm người dùng quan tâm đến xu hướng giá bán và sự biến động của thị trường.

Thông qua Dashboard, nhà đầu tư có thể:

- Theo dõi mức giá trung bình của bất động sản.
- So sánh giá giữa các khu vực.
- Xác định khu vực có nhiều giao dịch.
- Quan sát xu hướng giao dịch theo thời gian.
- Hỗ trợ đánh giá tiềm năng đầu tư.

2.3.2 Nhà phân tích dữ liệu

Đối với Data Analyst hoặc Data Scientist, Dashboard đóng vai trò là công cụ hỗ trợ khám phá dữ liệu.

Người phân tích có thể:

- Quan sát phân bố dữ liệu.
- Phát hiện dữ liệu bất thường.
- Kiểm tra xu hướng.
- Phân tích mối quan hệ giữa các thuộc tính.
- Khai thác Insight phục vụ nghiên cứu.

2.3.3 Người học và giảng viên

Ngoài mục đích phân tích dữ liệu, dự án còn phục vụ hoạt động học tập và nghiên cứu.

Dashboard giúp sinh viên hiểu rõ quy trình triển khai một dự án Data Analytics từ giai đoạn thu thập dữ liệu đến khi xây dựng sản phẩm hoàn chỉnh bằng Python và Streamlit.

2.4 Các yêu cầu của khách hàng

Sau khi phân tích nhu cầu sử dụng, nhóm xác định Dashboard cần đáp ứng các yêu cầu sau:

- Hiển thị các chỉ số thống kê quan trọng.
- Cho phép lọc dữ liệu theo nhiều điều kiện.
- Trực quan hóa dữ liệu bằng nhiều loại biểu đồ.
- Giao diện đơn giản, dễ sử dụng.
- Dữ liệu phản hồi nhanh khi thay đổi bộ lọc.
- Các biểu đồ có khả năng tương tác.
- Hỗ trợ người dùng dễ dàng khám phá dữ liệu.

Các yêu cầu trên là cơ sở để lựa chọn các thư viện Python và thiết kế giao diện Dashboard.

2.5 Các câu hỏi cần giải quyết

Một Dashboard hiệu quả cần trả lời được các câu hỏi mà người dùng thường xuyên quan tâm.

Trong dự án này, Dashboard được xây dựng nhằm giải quyết các câu hỏi sau:

- Có bao nhiêu giao dịch bất động sản trong bộ dữ liệu?
- Tổng giá trị giao dịch là bao nhiêu?
- Giá bán trung bình của bất động sản là bao nhiêu?
- Khu vực nào có số lượng giao dịch nhiều nhất?
- Khu vực nào có giá trị giao dịch cao nhất?
- Loại hình bất động sản nào phổ biến?
- Giá bán phân bố như thế nào giữa các Borough?
- Xu hướng giao dịch thay đổi theo thời gian ra sao?
- Giá bán có sự chênh lệch lớn giữa các khu vực hay không?

- Những yếu tố nào ảnh hưởng nhiều đến giá trị giao dịch?

Việc xác định rõ các câu hỏi này giúp định hướng toàn bộ quá trình xử lý dữ liệu và lựa chọn biểu đồ phù hợp.

2.6 Các chỉ số cần theo dõi

Để đáp ứng yêu cầu của người dùng, Dashboard cần hiển thị các chỉ số tổng quan phản ánh tình trạng của bộ dữ liệu.

Các KPI chính bao gồm:

- Tổng số giao dịch.
- Tổng giá trị giao dịch.
- Giá bán trung bình.
- Giá bán cao nhất.
- Giá bán thấp nhất.
- Tổng số Borough.
- Tổng số Neighborhood.
- Tổng số loại hình bất động sản.

Các chỉ số này giúp người dùng nhanh chóng nắm bắt tổng quan bộ dữ liệu mà không cần quan sát toàn bộ bảng dữ liệu.

2.7 Yêu cầu về trực quan hóa dữ liệu

Mỗi loại dữ liệu sẽ phù hợp với một dạng biểu đồ khác nhau. Vì vậy, việc lựa chọn biểu đồ cần dựa trên mục tiêu phân tích thay vì yếu tố thẩm mỹ.

Trong dự án, các loại biểu đồ được sử dụng gồm:

- Biểu đồ cột (Bar Chart): Dùng để so sánh số lượng giao dịch hoặc giá trị giao dịch giữa các khu vực.
- Biểu đồ đường (Line Chart): Dùng để theo dõi xu hướng giao dịch theo thời gian.
- Biểu đồ tròn (Pie Chart): Thể hiện tỷ trọng của từng nhóm dữ liệu trong tổng thể.
- Biểu đồ Box Plot: Phân tích sự phân bố dữ liệu và phát hiện giá trị ngoại lệ.
- Biểu đồ Histogram: Quan sát tần suất xuất hiện của giá bán hoặc diện tích.

- Biểu đồ phân tán (Scatter Plot): Dùng để phân tích mối tương quan giữa hai biến số (như Diện tích, Thu nhập với Giá bán) và đánh giá độ chính xác của mô hình Machine Learning qua đường so sánh Giá thực tế vs Giá dự báo ($y=x$).
- Bản đồ không gian & Bản đồ nhiệt (Spatial Map & Heatmap): Dùng để trực quan hóa mật độ giao dịch và phân bố mặt bằng giá bất động sản theo tọa độ địa lý thực tế trên bản đồ 5 quận New York.
- Biểu đồ cột ngang xếp hạng (Horizontal Bar Chart): Dùng để hiển thị thứ hạng mức độ quan trọng của các đặc trưng (Feature Importance) và tỷ trọng đóng góp của các tiện ích công cộng vào việc định giá.
- Thẻ chỉ số tổng hợp (KPI Metric Cards): Trình bày nhanh các chỉ số đo lường hiệu suất cốt lõi của thị trường như Tổng số giao dịch, Giá trung vị, Tỷ lệ tăng trưởng YoY và Tỷ lệ giao dịch trên 1 triệu USD.

Việc lựa chọn đúng biểu đồ sẽ giúp người dùng hiểu dữ liệu nhanh hơn và hạn chế việc diễn giải sai kết quả phân tích.

2.8 Yêu cầu về hệ thống Dashboard

Dashboard được xây dựng bằng Streamlit nên cần đáp ứng các yêu cầu sau:

- Giao diện trực quan và phân luồng nghiệp vụ khoa học.
- Bố cục rõ ràng.
- Dễ dàng thao tác.
- Hỗ trợ nhiều bộ lọc.
- Hiển thị KPI ở vị trí nổi bật.
- Bộ lọc đa chiều và cập nhật theo thời gian thực.
- Tích hợp mô hình AI-ML tương tác.
- Trực quan hóa không gian địa lý (GPS).
- Thời gian phản hồi nhanh.
- Khả năng mở rộng trong tương lai.

Ngoài việc hiển thị thông tin, Dashboard còn đóng vai trò là công cụ hỗ trợ phân tích, giúp người dùng tương tác trực tiếp với dữ liệu thay vì chỉ xem các báo cáo tĩnh.

2.9 Quy trình thực hiện dự án

Sau khi xác định yêu cầu của khách hàng, nhóm xây dựng quy trình thực hiện dự án theo các bước sau:

1. Thu thập dữ liệu.
2. Làm sạch dữ liệu.
3. Chuyển đổi dữ liệu.
4. Khám phá dữ liệu (EDA).
5. Phân tích dữ liệu.
6. Thiết kế Dashboard.
7. Kiểm thử và đánh giá kết quả.
8. Hoàn thiện báo cáo.

Quy trình này đảm bảo mọi bước thực hiện đều có sự liên kết chặt chẽ, từ dữ liệu đầu vào đến sản phẩm cuối cùng là Dashboard phân tích dữ liệu.

3. LÀM SẠCH VÀ CHUYỂN ĐỔI DỮ LIỆU

3.1 Giới thiệu

Sau khi hoàn thành quá trình thu thập dữ liệu, dữ liệu chưa thể sử dụng ngay cho việc phân tích và trực quan hóa. Trong thực tế, dữ liệu thô thường chứa nhiều lỗi như giá trị bị thiếu, dữ liệu trùng lặp, sai kiểu dữ liệu hoặc định dạng không thống nhất. Nếu những vấn đề này không được xử lý trước khi phân tích, kết quả thu được có thể không chính xác và làm giảm độ tin cậy của Dashboard.

Vì vậy, bước làm sạch và chuyển đổi dữ liệu (Data Cleaning & Data Transformation) đóng vai trò đặc biệt quan trọng trong toàn bộ dự án. Đây là giai đoạn giúp nâng cao chất lượng dữ liệu, chuẩn hóa cấu trúc và tạo nền tảng cho các bước phân tích ở những chương tiếp theo.

Trong dự án này, toàn bộ quá trình làm sạch dữ liệu được thực hiện bằng ngôn ngữ lập trình Python với thư viện Pandas. Sau khi xử lý, dữ liệu được lưu thành tệp DATA.csv để phục vụ cho việc phân tích và xây dựng Dashboard.

3.2 Mục tiêu của quá trình làm sạch dữ liệu

Quá trình làm sạch dữ liệu được thực hiện nhằm đạt được các mục tiêu sau:

- Phát hiện và xử lý các giá trị bị thiếu.
- Loại bỏ các bản ghi không hợp lệ.

- Chuẩn hóa kiểu dữ liệu.
- Chuẩn hóa định dạng ngày tháng.
- Loại bỏ dữ liệu trùng lặp.
- Kiểm tra và xử lý các giá trị bất thường.
- Đảm bảo dữ liệu có tính nhất quán trước khi phân tích.
- Tạo tập dữ liệu sạch phục vụ Dashboard.

Việc thực hiện đầy đủ các bước trên giúp hạn chế sai số trong quá trình thống kê và trực quan hóa dữ liệu.

3.3 Quy trình làm sạch dữ liệu

Quá trình làm sạch dữ liệu của dự án được thực hiện theo các bước chính sau:

Bước 1: Đọc dữ liệu từ tệp CSV.

Bước 2: Kiểm tra cấu trúc dữ liệu.

Bước 3: Kiểm tra kiểu dữ liệu của từng cột.

Bước 4: Kiểm tra giá trị thiếu.

Bước 5: Kiểm tra dữ liệu trùng lặp.

Bước 6: Chuẩn hóa dữ liệu.

Bước 7: Chuyển đổi kiểu dữ liệu.

Bước 8: Kiểm tra dữ liệu sau xử lý.

Bước 9: Xuất dữ liệu sang tệp Excel và CSV.

Quy trình này được xây dựng theo trình tự hợp lý nhằm đảm bảo mỗi bước xử lý đều dựa trên kết quả của bước trước đó.

3.4 Đọc dữ liệu bằng Pandas

Bước đầu tiên là đọc dữ liệu từ tệp `Crawl_data_NYC.csv` vào `DataFrame`.

Việc sử dụng `DataFrame` mang lại nhiều lợi ích:

- Dễ dàng quan sát dữ liệu.
- Thực hiện thống kê nhanh.
- Hỗ trợ lọc dữ liệu.

- Hỗ trợ xử lý dữ liệu với hiệu năng cao.
- Tích hợp nhiều hàm xử lý mạnh mẽ.

Sau khi đọc dữ liệu, cần kiểm tra số lượng dòng và cột để đảm bảo dữ liệu được tải đầy đủ.

3.5 Kiểm tra cấu trúc dữ liệu

Sau khi đọc dữ liệu, bước tiếp theo là kiểm tra tổng quan bộ dữ liệu.

Các nội dung cần kiểm tra bao gồm:

- Số lượng bản ghi.
- Số lượng cột.
- Tên các trường dữ liệu.
- Kiểu dữ liệu của từng trường.
- Giá trị thiếu.
- Dung lượng bộ nhớ sử dụng.

Việc hiểu rõ cấu trúc dữ liệu giúp lựa chọn phương pháp xử lý phù hợp cho từng loại dữ liệu.

3.6 Kiểm tra giá trị thiếu (Missing Values)

Dữ liệu thiếu là một trong những vấn đề phổ biến nhất trong các bộ dữ liệu thực tế.

Nguyên nhân có thể đến từ:

- Lỗi trong quá trình nhập liệu.
- Thiếu thông tin từ nguồn dữ liệu.
- Dữ liệu không được cập nhật đầy đủ.
- Lỗi trong quá trình thu thập dữ liệu.

Nếu không xử lý các giá trị thiếu, nhiều phép tính thống kê như trung bình, tổng hoặc tỷ lệ sẽ cho kết quả không chính xác.

Trong dự án, các giá trị thiếu được kiểm tra trên toàn bộ các cột trước khi tiến hành xử lý. Tùy thuộc vào đặc điểm của từng trường dữ liệu, nhóm lựa chọn phương pháp xử lý phù hợp nhằm hạn chế tối đa việc làm thay đổi bản chất của dữ liệu.

3.7 Kiểm tra dữ liệu trùng lặp

Dữ liệu trùng lặp có thể làm tăng số lượng bản ghi một cách giả tạo và ảnh hưởng trực tiếp đến các kết quả thống kê.

Ví dụ:

- Tổng số giao dịch bị tăng lên.
- Giá trị trung bình bị sai lệch.
- Tần suất xuất hiện của một khu vực không còn chính xác.

Do đó, trước khi phân tích, cần kiểm tra toàn bộ dữ liệu để xác định các bản ghi bị lặp và loại bỏ nếu cần thiết.

Việc loại bỏ dữ liệu trùng lặp giúp đảm bảo mỗi giao dịch chỉ được ghi nhận một lần trong bộ dữ liệu.

3.8 Chuẩn hóa kiểu dữ liệu

Trong quá trình thu thập, một số trường dữ liệu có thể chưa đúng kiểu dữ liệu.

Ví dụ:

- Giá bán được lưu dưới dạng chuỗi.
- Ngày giao dịch chưa ở định dạng DateTime.
- Diện tích được lưu dưới dạng văn bản.

Nếu không chuyển đổi đúng kiểu dữ liệu, các phép tính thống kê sẽ không thể thực hiện hoặc cho kết quả sai.

Do đó, các trường dữ liệu được chuyển đổi về đúng kiểu dữ liệu trước khi phân tích.

3.9 Chuyển đổi dữ liệu

Sau khi làm sạch, dữ liệu tiếp tục được chuyển đổi nhằm phục vụ cho việc phân tích và trực quan hóa.

Các bước chuyển đổi có thể bao gồm:

- Chuẩn hóa định dạng ngày tháng.
- Chuẩn hóa kiểu dữ liệu số.
- Loại bỏ khoảng trắng thừa.

- Chuẩn hóa tên các trường dữ liệu.
- Đồng nhất cách biểu diễn dữ liệu.

Việc chuyển đổi dữ liệu giúp các biểu đồ và Dashboard hoạt động ổn định, đồng thời giảm nguy cơ phát sinh lỗi trong quá trình xử lý.

3.10 Kiểm tra dữ liệu sau xử lý

Sau khi hoàn thành toàn bộ các bước làm sạch và chuyển đổi, dữ liệu được kiểm tra lại để đảm bảo:

- Không còn dữ liệu trùng lặp.
- Các trường dữ liệu đã đúng kiểu.
- Dữ liệu có cấu trúc thống nhất.
- Không xuất hiện lỗi định dạng.
- Dữ liệu sẵn sàng cho bước phân tích.

Đây là bước kiểm tra cuối cùng trước khi chuyển sang giai đoạn khám phá dữ liệu (Exploratory Data Analysis).

3.11 Xuất dữ liệu đã làm sạch

Sau khi hoàn thành quá trình xử lý, dữ liệu được lưu thành tệp DATA.csv.

Việc sử dụng tệp dữ liệu đã làm sạch thay vì dữ liệu gốc mang lại nhiều lợi ích:

- Tăng tốc độ xử lý ở các bước tiếp theo.
- Giảm nguy cơ phát sinh lỗi khi phân tích.
- Đảm bảo tính nhất quán giữa Dashboard và báo cáo.
- Giúp việc chia sẻ dữ liệu giữa các thành viên trở nên thuận tiện hơn.
- Dễ dàng tái sử dụng cho các nghiên cứu hoặc dự án mở rộng trong tương lai.

Tệp dữ liệu này sẽ được sử dụng xuyên suốt các chương tiếp theo để thực hiện phân tích dữ liệu, xây dựng biểu đồ trực quan và phát triển Dashboard bằng Streamlit.

4. XỬ LÝ DỮ LIỆU

4.1 Giới thiệu

Trong kỷ nguyên kinh tế số và phân tích dữ liệu lớn (Big Data Analytics), dữ liệu thô (Raw Data) thu thập từ các hệ thống giao dịch công quyền thường bị phân mảnh, chứa nhiều nhiễu (Noise), giá trị khuyết thiếu (Missing values), trùng lặp (Duplicates) và các ngoại lai phi thực tế (Outliers). Đối với thị trường bất động sản (BDS) New York City (NYC) – một trong những thị trường tài sản phức tạp và biến động bậc nhất thế giới – chất lượng của dữ liệu đầu vào quyết định trực tiếp tới độ tin cậy của toàn bộ hệ thống Business Intelligence (BI) và các mô hình dự báo giá.

Chương 4 tập trung trình bày toàn bộ quy trình tiền xử lý dữ liệu (Data Preprocessing), kỹ thuật trích xuất và biến đổi đặc trưng (Feature Engineering), các phương pháp thống kê mô tả, phân tích nhóm (Aggregation), tính toán chỉ số hiệu suất chính (KPIs) và thiết kế mô hình hóa dữ liệu (Data Modeling) theo kiến trúc Star Schema tối ưu cho hệ thống báo cáo thời gian thực.

4.2 Mục tiêu của quá trình xử lý dữ liệu


Mục tiêu cốt lõi của giai đoạn xử lý dữ liệu trong đồ án bao gồm:

- Làm sạch và chuẩn hóa dữ liệu: Loại bỏ 100% các dòng trùng lặp hoàn toàn và trùng lặp theo khóa nghiệp vụ (Business Key); xử lý toàn diện các thuộc tính bị khuyết thiếu; chuẩn hóa kiểu dữ liệu định dạng ngày tháng, số học và chuỗi ký tự.
- Xử lý bất thường và ngoại lai (Outliers): Nhận diện và phân loại chính xác các giao dịch không mang tính thị trường (ví dụ: chuyển nhượng nội bộ gia đình với giá: (⚠️ Failed to render LaTeX: KaTeX parse error: Unexpected character: '\' at position 3: <\<\1,000 >\$100,000,000\$).
- Khai phá & Xây dựng biến phái sinh (Feature Engineering): Tính toán các biến mới như: Tuổi công trình (*Building Age*), Đơn giá thực tế trên mỗi feet vuông (*Price per Sqft Real*), Phân nhóm thời kỳ xây dựng (*Era Built*), và Điểm tiện ích xung quanh (*Amenity Score*).
- Mô hình hóa kho dữ liệu (Data Warehouse Modeling): Thiết kế và chuyển đổi từ bảng phẳng (Flat Table) sang mô hình Lược đồ hình sao kết hợp tuyệt (Starflake Schema).
- Chuẩn bị dữ liệu phục vụ Trực quan hóa: Tối ưu hóa cấu trúc dữ liệu cho Dashboard Streamlit/Plotly.

4.3 Quy trình xử lý dữ liệu

Quy trình xử lý dữ liệu được thiết kế theo chuẩn ETL (Extract – Transform – Load) khép kín gồm 5 giai đoạn:

Hình 1: Sơ đồ quy trình xử lý dữ liệu tổng thể (Data Processing Pipeline)



- Bước 1 (Extract): Tải dữ liệu giao dịch từ NYC Department of Finance kết hợp dữ liệu kinh tế xã hội (US Census) và tọa độ tiện ích (OpenStreetMap API).
- Bước 2 (Transform - Data Cleaning): Phát hiện trùng lặp, lọc các cột có tỷ lệ missing, nội suy dữ liệu khuyết thiếu bằng trung vị (Median) theo cụm địa lý.
- Bước 3 (Transform - Feature Engineering): Tính toán tuổi nhà, diện tích chuẩn hóa, nhãn phân loại tài sản dân cư/thương mại.
- Bước 4 (Data Modeling & Load): Tách dữ liệu thành Fact và Dimensions, tạo khóa chính/khóa ngoại, lưu trữ vào SQLite/PostgreSQL Data Warehouse.
- Bước 5 (Serve): Cung cấp các view dữ liệu đã tiền tổng hợp (Pre-aggregated) phục vụ Dashboard Streamlit và tập huấn luyện cho mô hình Machine Learning.

4.4 Khảo sát tổng quan dữ liệu

Tập dữ liệu thô ban đầu gồm 49,041 bản ghi với 36 trường thuộc tính. Qua khảo sát ban đầu, dữ liệu được phân chia thành 3 nhóm thuộc tính chính:

Bảng 2: Phân loại nhóm thuộc tính dữ liệu thô

Nhóm thuộc tính	Các trường tiêu biểu	Ý nghĩa nghiệp vụ	Kiểu dữ liệu gốc
Định danh & Không gian	borough, neighborhood, block, lot, address, zip_code	Xác định vị trí địa lý, phân vùng quy hoạch bất động sản tại NYC	Object, Float64
Đặc tính công trình	building_class_category, residential_units, commercial_units, gross_sqft, land_sqft, year_built	Quy mô, công năng sử dụng, diện tích mặt sàn và năm khởi công	Object, Float64
Giao dịch tài chính	sale_price, sale_date, tax_class_at_time_of_sale	Giá bán thực tế bằng USD, ngày chuyển nhượng và nhóm thuế áp dụng	Float64, Object

Các vấn đề phát hiện trong dữ liệu thô:

1. Dữ liệu khuyết thiếu nghiêm trọng: Cột easement thiếu, cột apartment_number thiếu, diện tích gross_sqft và land_sqft thiếu.
2. Nhiều kiểu dữ liệu: Cột ngày bán sale_date bị lưu ở dạng chuỗi ký tự (object), mã bưu chính zip_code bị lưu ở dạng số thực (float64) dẫn đến mất số 0 ở đầu.
3. Giá trị giao dịch \$1,000\$ (chuyển nhượng quyền thừa kế hoặc cho tặng giữa các thành viên trong gia đình).
4. Năm xây dựng bất thường: Tồn tại các giá trị year_built = 0 hoặc các tòa nhà có tuổi thọ lớn hơn 200 năm cần được xác minh.

4.5 Thống kê mô tả

Thống kê mô tả (Descriptive Statistics) là bước giúp tóm tắt bộ dữ liệu thông qua các chỉ số thống kê cơ bản.

Một số chỉ số thường được sử dụng trong dự án bao gồm:

- Số lượng bản ghi.
- Giá trị trung bình (Mean).
- Giá trị trung vị (Median).
- Giá trị nhỏ nhất (Minimum).
- Giá trị lớn nhất (Maximum).
- Độ lệch chuẩn (Standard Deviation).

Các chỉ số này giúp người dùng có cái nhìn tổng quan về sự phân bố của dữ liệu trước khi đi sâu vào phân tích.

Bảng 3: Bảng thống kê mô tả chi tiết tập dữ liệu (47,039 bản ghi sạch):

Tên biến (Feature)	Mean (Trung bình)	Median (Trung vị)	Min (Tối thiểu)	Max (Tối đa)	Std (Độ lệch chuẩn)	IQR (Độ trải giữa)
sale_price (\$)	1,166,067	885,000	4,000	2,957,233	838,829	845,000
gross_sqft (ft ²)	1,456.1	1,460	0	3,264	989.01	1,120
land_sqft (ft ²)	1,991.11	2,000	250	3,850	1,137.52	1,400
year_built (Năm)	1950.65	1945	1800	2025.00	34.50	45
residential_units	2.16	1	0	1,092.00	16.70	1

commercial _units	0.23	0	0	472.00	5.19	0
total_units	2.39	1	0	1,097.00	17.53	1

4.6 Nhóm dữ liệu (Grouping Data)

Sử dụng “df.groupby('borough')” để đánh giá mức độ chênh lệch giá trị và khối lượng giao dịch giữa 5 quận của New York:

Bảng 4: Thống kê khối lượng và giá trị giao dịch bất động sản theo từng quận

Mã Quận	Tên Quận (Borough)	Số giao dịch (Count)	Tỷ lệ (%)	Giá trung bình (\$)	Giá trung vị (\$)	Tổng giá trị giao dịch (Tỷ \$)
1	Manhattan	12,819	27.25%	1,527,840\$	1,246,250\$	19.58\$
2	Bronx	3,524	7.49%	850,336\$	709,500\$	2.99\$
3	Brooklyn	11,952	25.41%	1,353,561\$	1,100,000\$	16.18\$
4	Queens	14,469	30.76%	874,892\$	755,000\$	12.66\$
5	Staten Island	4,275	9.09%	802,826\$	725,000\$	3.43\$
Tổng	Toàn TP New York	47,039	100.0%	\$1,166,067	\$885,000	\$54.84

Nhận định:

- Queens dẫn đầu về tính thanh khoản (chiếm tổng lượng giao dịch).
- Manhattan có giá trị giao dịch đắt đỏ nhất

- Bronx và Staten Island là các khu vực có mức giá hợp lý nhất cho phân khúc nhà ở bình dân.

4.7 Tính toán các chỉ số KPI

Các chỉ số KPI tài chính và hoạt động được xác lập bằng các công thức toán học tường minh nhằm làm căn cứ hiển thị trên các thẻ Header Card của Dashboard:

1. Tổng quy mô thị trường (Total Market Volume - TMV):

$$TMV = \sum_{i=1}^N \text{sale_price}_i = \$54,840,000,000 \text{ (54.84 Tỷ USD)}$$

2. Đơn giá trung bình trên mỗi feet vuông (Average Price Per Sqft - APPS):

$$APPS = \frac{\sum_{i \in \text{valid}} \text{sale_price}_i}{\sum_{i \in \text{valid}} \text{gross_sqft}_i} = \$800.82/\text{ft}^2$$

3. Tỷ lệ BĐS dân cư (Residential Dominance Ratio - RDR):

$$RDR = \frac{\sum \text{residential_units}}{\sum \text{total_units}} \times 100\% = \frac{101,831}{112,625} \times 100\% = 90.41\%$$

4. Tỷ lệ giao dịch nội bộ / phi thương mại (Internal Transfer Rate):

$$ITR = \frac{N_{\text{price} < \$1000}}{N_{\text{total}}} \times 100\% = \frac{1,299}{49,041} \times 100\% = 2.65\%$$

5. Điểm số tiện ích tổng hợp (Composite Amenity Score - CAS):

$$CAS_j = \min \left(10, \text{total_units}_j \times 0.15 + \frac{10}{\text{dist_center}_j} \right)$$

(Trong đó dist_center là khoảng cách tính từ trung tâm quận đến vùng lõi kinh tế Manhattan).

4.8 Chuẩn bị dữ liệu cho trực quan hóa

Để hệ thống Dashboard Streamlit đạt hiệu năng mượt mà, kỹ thuật chuẩn bị dữ liệu bao gồm:

1. **Kỹ thuật Pre-Aggregation (Tiền tổng hợp):** Thay vì gửi toàn bộ dòng dữ liệu thô lên trình duyệt mỗi khi lọc, dữ liệu được gom nhóm trước (Pre-aggregated) ở tầng database theo bảng tổng hợp: (borough, neighborhood, sale_year).
2. **Tối ưu hóa kiểu dữ liệu bộ nhớ (Memory Downcasting):**
Chuyển borough_id từ int64 sang int8.
 - Chuyển year_built sang int16.
 - Chuyển các cột phân loại lặp lại (borough, building_category) sang kiểu category của Pandas, giúp giảm dung lượng RAM tiêu thụ (từ xuống còn).
3. **Cơ chế Caching tầng ứng dụng (@st.cache_data):** Đánh chỉ mục (Indexing) cho hàm tải dữ liệu trong Streamlit, giúp lưu dữ liệu vào bộ nhớ đệm RAM sau lần tải đầu tiên, thời gian phản hồi cho các lần lọc tiếp theo đạt mức gần như tức thì ().
4. **Xử lý dữ liệu không gian GeoJSON / Mapbox:** Định dạng chuẩn cặp tọa độ (latitude, longitude) ở dạng float32, loại bỏ các tọa độ hoặc nằm ngoài phạm vi bao NYC ().

4.9 Bổ sung phần kỹ thuật chuyên sâu

4.9.1 Mã nguồn Python/Pandas thực hiện toàn bộ quy trình tiền xử lý

Trước khi đi vào chi tiết mã nguồn, toàn bộ quy trình biến đổi dữ liệu từ thô (Raw) sang sạch (Cleaned) được tổng hợp qua bảng sau:

Bảng 5: Bảng tóm tắt quy trình Pipeline tiền xử lý dữ liệu

Bước	Tên giai đoạn (Stage)	Thao tác kỹ thuật chính (Actions)	Đầu vào (Input) → Đầu ra (Output)	Ý nghĩa & Lý do kỹ thuật (Rationale)
1	Đọc & Chuẩn hóa Schema	Đọc CSV với low_memory=False, chuẩn hóa tên cột về snake_case.	49,041 dòng × 36 cột (Tên lộn xộn) → 36 cột chuẩn snake_case	Đồng bộ hóa quy chuẩn lập trình, tránh lỗi truy cập thuộc tính do khoảng trắng hoặc ký tự đặc biệt.
2	Xử lý Duplicates & Missing	- drop_duplicates() loại dòng trùng lặp 100%. - Drop cột thiếu > 50% (easement, apartment_number). - Điền Median cho cột số, 'UNKNOWN' cho cột chuỗi.	36 cột → 30 cột sạch (0 ô Missing ở các cột quan trọng)	- Tránh việc đếm trùng giao dịch. - Giữ lại các trường có ý nghĩa thống kê cao, loại bỏ nhiều do thiếu dữ liệu trầm trọng.
3	Xử lý Ngoại lai (Outliers)	- Gắn cờ is_internal_transfer (< \$1,000). - Gắn cờ is_luxury (> \$100M). - Áp dụng IQR Capping cho dải giá thị trường.	49,041 bản ghi được phân loại và giới hạn ngưỡng IQR	Giúp phân tách rõ ràng giữa giao dịch cho tặng/nội bộ và giao dịch thương mại, tránh méo mó mô hình phân tích.

4	Trích xuất đặc trưng (Feature Engineering)	- Chuẩn hóa year_built hợp lệ (1800 – 2026). - Tính building_age = 2026 - year_built. - Phân nhóm thể hệ era_built (Pre-War, dern...). - Tính đơn giá price_per_sqft_realt.	Tạo thêm 4 trường phái sinh mới có giá trị kinh tế cao	Cung cấp các biến số phi tuyến quan trọng phản ánh chất lượng và khấu hao của bất động sản.
---	---	--	--	---

Tiếp theo là mã nguồn Python nguyên bản & Giải thích Logic từng khối:

Hình 2: Đọc và chuẩn hóa cấu trúc cột

```
import pandas as pd
import numpy as np
from datetime import datetime

# =====
# BƯỚC 1: ĐỌC DỮ LIỆU VÀ TỐI ƯU HÓA SCHEMA
# =====
def load_and_inspect(file_path: str) -> pd.DataFrame:
    print(f"[INFO] Bắt đầu đọc dữ liệu từ: {file_path}")
    df = pd.read_csv(file_path, low_memory=False)

    # Chuẩn hóa tên cột: chữ thường, thay khoảng trắng và dấu gạch nối bằng '_'
    df.columns = df.columns.str.strip().str.lower().str.replace(' ', '_').str.replace('-', '_')
    print(f"[INFO] Kích thước dữ liệu gốc: {df.shape[0]:,} dòng x {df.shape[1]} cột")
    return df
```

Giải thích logic kỹ thuật:

- low_memory=False: Buộc thư viện Pandas đọc toàn bộ file vào bộ nhớ rồi mới suy luận kiểu dữ liệu (dtype). Điều này ngăn chặn triệt để lỗi xung đột kiểu dữ liệu (Mixed Dtype Warning) khi một cột vừa chứa số vừa chứa chữ.

Hình 3: Kiểm tra & xử lý MISSING VALUES, DUPLICATES

```
# =====
# BƯỚC 2: KIỂM TRA & XỬ LÝ MISSING VALUES, DUPLICATES
# =====
def clean_missing_and_duplicates(df: pd.DataFrame) -> pd.DataFrame:
    # 2.1 Xử lý Duplicate
    initial_rows = len(df)
    df = df.drop_duplicates()
    print(f"[CLEAN] Đã loại bỏ {initial_rows - len(df):,} dòng trùng lặp hoàn toàn.")

    # 2.2 Loại bỏ các cột missing > 50%
    missing_ratio = df.isnull().mean()
    drop_cols = missing_ratio[missing_ratio > 0.5].index.tolist()
    # Giữ lại các cột quan trọng nếu cần xử lý riêng, còn lại drop
    cols_to_drop = [c for c in drop_cols if c in ['easement', 'apartment_number']]
    df = df.drop(columns=cols_to_drop, errors='ignore')
    print(f"[CLEAN] Đã drop các cột thiếu >50%: {cols_to_drop}")

    # 2.3 Imputation (Điền khuyết thiếu)
    # Cột số: Điền Median; Cột chuỗi: Điền 'UNKNOWN' hoặc Mode
    num_cols = df.select_dtypes(include=[np.number]).columns
    for col in num_cols:
        if df[col].isnull().any():
            median_val = df[col].median()
            df[col] = df[col].fillna(median_val)

    cat_cols = df.select_dtypes(include=['object']).columns
    for col in cat_cols:
        if df[col].isnull().any():
            df[col] = df[col].fillna('UNKNOWN')

    return df
```

Giải thích logic kỹ thuật:

- `drop_duplicates()` : Loại bỏ các bản ghi trùng lặp 100% do quá trình trích xuất dữ liệu nhiều lần gây ra, đảm bảo mỗi giao dịch chỉ được tính một lần duy nhất.
- Chiến lược loại bỏ cột thiếu > 50%:
 - + Các trường như `easement` (khuyết thiếu 100%) và `apartment_number` (khuyết thiếu 75.32%) có tỷ lệ mất mát thông tin quá lớn. Nếu cố tình điền khuyết thiếu sẽ tạo ra dữ liệu giả mạo (Artificial Noise). Do đó, quyết định Drop các cột này là hoàn toàn chính xác về mặt Khoa học dữ liệu.
- Chiến lược nội suy (Imputation):
 - + Đối với cột Số học (`np.number`): Điền bằng Trung vị (`median()`). Vì dữ liệu giá nhà và diện tích có độ lệch (Skewness) rất cao, trung vị là thước đo trung tâm vững chắc (Robust Statistic), không bị kéo lệch bởi các con số siêu lớn hay siêu nhỏ.

- + Đối với cột Chuỗi (object): Điền bằng chuỗi 'UNKNOWN'. Giúp mô hình xem việc “thiếu thông tin”; như một phân lớp danh mục độc lập, không làm mất dòng dữ liệu.

Hình 4: Xử lý ngoại lai và gắn cờ nghiệp vụ

```
# =====
# BƯỚC 3: XỬ LÝ OUTLIERS (IQR CLIPPING & BUSINESS FLAGS)
# =====

def handle_outliers(df: pd.DataFrame) -> pd.DataFrame:
    # Gắn cờ giao dịch nội bộ / chuyển nhượng phi thương mại
    df['is_internal_transfer'] = np.where(df['sale_price'] < 1000, 1, 0)

    # Gắn cờ giao dịch siêu sang
    df['is_luxury'] = np.where(df['sale_price'] > 100_000_000, 1, 0)

    # Áp dụng IQR cho giá bán thông thường phục vụ mô hình phân tích
    valid_sales = df[df['sale_price'] >= 1000]['sale_price']
    Q1 = valid_sales.quantile(0.25)
    Q3 = valid_sales.quantile(0.75)
    IQR = Q3 - Q1
    lower_bound = max(1000, Q1 - 1.5 * IQR)
    upper_bound = Q3 + 1.5 * IQR

    print(f"[OUTLIER] Ngưỡng IQR hợp lệ: [{lower_bound:,.0f} $ -> {upper_bound:,.0f} $]")
    df['sale_price_capped'] = df['sale_price'].clip(lower=lower_bound, upper=upper_bound)
    return df
```

Giải thích logic kỹ thuật:

- Gắn cờ nhị phân (Business Flags):
 - + is_internal_transfer = 1 cho các căn giá < \$1,000: Đây là các giao dịch mang tính chất cho tặng, thừa kế quyền sử dụng đất giữa các thành viên gia đình (không phản ánh giá trị thị trường).
 - + is_luxury = 1 cho các căn giá > \$100,000,000: Phân loại riêng nhóm bất động sản siêu cao cấp.

Ý nghĩa: Thay vì xóa bỏ làm mất lịch sử dữ liệu, việc gắn cờ giúp hệ thống lọc linh hoạt khi phân tích.

- Phương pháp Tứ phân vị IQR (Interquartile Range):
 - + Tính $IQR = Q_3 - Q_1$ trên nhóm giao dịch thương mại ($\geq \$1,000$).
 - + Ngưỡng dưới: Lower Bound = $\max(1000, Q_1 - 1.5 \times IQR)$.
 - + Ngưỡng trên: Upper Bound = $Q_3 + 1.5 \times IQR$.
 - + Hàm .clip() đưa các giá trị vượt ngưỡng về lại biên an toàn, giúp loại bỏ các điểm dị biệt gây nhiễu cho mô hình thống kê.

Hình 5: FEATURE ENGINEERING chuyên sâu

```
# =====
# BƯỚC 4: FEATURE ENGINEERING CHUYÊN SÂU (YEAR BUILT & THUỘC TÍNH MỚI)
# =====
def engineer_features(df: pd.DataFrame) -> pd.DataFrame:
    current_year = 2026

    # 4.1 Chuẩn hóa Year Built (thay giá trị <= 0 hoặc > current_year bằng Median)
    valid_year_mask = (df['year_built'] > 1800) & (df['year_built'] <= current_year)
    median_year = df.loc[valid_year_mask, 'year_built'].median()
    df['year_built_clean'] = np.where(valid_year_mask, df['year_built'], median_year).astype(int)

    # 4.2 Tính Tuổi công trình (Building Age)
    df['building_age'] = current_year - df['year_built_clean']

    # 4.3 Phân nhóm thể hệ kiến trúc (Building Era)
    bins = [-np.inf, 1939, 1979, 1999, current_year]
    labels = ['Pre-War (<1940)', 'Mid-Century (1940-1979)', 'Late-20th (1980-1999)', 'Modern (2000+)']
    df['era_built'] = pd.cut(df['year_built_clean'], bins=bins, labels=labels)

    # 4.4 Đơn giá thực tế trên mỗi feet vuông
    df['price_per_sqft_real'] = np.where(
        df['gross_sqft'] > 0,
        df['sale_price'] / df['gross_sqft'],
        np.nan
    )

    # Điền giá trị missing của đơn giá bằng median theo từng quận
    df['price_per_sqft_real'] = df.groupby('borough')['price_per_sqft_real'].transform(
        lambda x: x.fillna(x.median())
    )

    print("[ENGINEERING] Đã tạo thành công các biến: building_age, era_built, price_per_sqft_real.")
    return df
```

Giải thích logic kỹ thuật:

- Chuẩn hóa year_built : Rất nhiều bản ghi bị lỗi nhập year_built = 0 hoặc lớn hơn năm hiện tại. Đoạn code lọc ra các năm hợp lệ (1800 – 2026), tính Trung vị năm xây dựng (1945) rồi dùng np.where thay thế các giá trị lỗi.
- Biến building_age (Tuổi công trình): building_age = 2026 - year_built_clean Phản ánh mức độ khấu hao tài sản và độ cũ/mới của tòa nhà.
- Biến era_built (Thời kỳ kiến trúc): Sử dụng pd.cut() để phân khúc các mốc lịch sử phát triển của New York:
 - + Pre-War (< 1940): Công trình cổ điển thời trước Thế chiến II (tường gạch dày, giá trị bảo tồn cao).
 - + Mid-Century (1940 – 1979): Thời kỳ tái thiết sau chiến tranh.
 - + Late-20th (1980 – 1999): Cuối thế kỷ 20.
 - + Modern (2000+): Công trình hiện đại, căn hộ cao cấp thế kỷ 21.
- Biến price_per_sqft_real (Đơn giá/sqft theo phân tầng Quận):

- + Tránh lỗi chia cho 0 bằng `np.where(df['gross_sqft'] > 0, ...)`.
- + Dùng hàm `groupby('borough').transform(...)` để điền khuyết thiếu theo Trung vị riêng của từng Quận (Ví dụ: Căn hộ ở Manhattan thiếu diện tích sẽ lấy đơn giá trung vị của Manhattan chứ không bị kéo sụt bởi giá rẻ của Bronx hay Staten Island).

4.9.2 Lý thuyết Mô hình hóa dữ liệu (Data Modeling)

Mô hình hóa dữ liệu là nghệ thuật và kỹ thuật cấu trúc hóa dữ liệu nhằm phục vụ mục đích phân tích, đảm bảo tính nhất quán, loại bỏ dư thừa và tối ưu hóa hiệu năng truy vấn. Quá trình thiết kế trải qua 3 cấp độ:

[1. Conceptual Model] → [2. Logical Model (Star Schema)] → [3. Physical Model (SQLite/Postgres)]

* Mô hình quan niệm (Conceptual Data Model):

Mô hình quan niệm trừu tượng hóa các thực thể thế giới thực trong nghiệp vụ BĐS New York và mối quan hệ giữa chúng:

- Thực thể QUẬN (Borough): Đơn vị hành chính cấp 1 (5 quận).
- Thực thể KHU DÂN CƯ (Neighborhood): Phân vùng vi mô thuộc quận.
- Thực thể VỊ TRÍ ĐỊA LÝ (Location): Gắn với địa chỉ, tọa độ GPS, mã bưu chính.
- Thực thể ĐẶC TÍNH CÔNG TRÌNH (Property): Phản ánh công năng, số tầng, diện tích, năm xây dựng.
- Thực thể CHỈ SỐ KINH TẾ - XÃ HỘI (Social Metrics): Mật độ dân số, thu nhập bình quân, số lượng trường học, bệnh viện.
- Thực thể GIAO DỊCH BÁN (Sales Transaction): Sự kiện trao đổi tài chính trung tâm kết nối tất cả các thực thể trên.

4.10 Chuẩn bị dữ liệu cho Dashboard Streamlit

Sau khi hoàn thành toàn bộ quá trình xử lý, dữ liệu được tổ chức theo cấu trúc phù hợp để tích hợp vào ứng dụng Streamlit.

Ở giai đoạn này, dữ liệu được tối ưu nhằm:

- Giảm thời gian tải Dashboard.
- Tăng tốc độ phản hồi khi người dùng thay đổi bộ lọc.
- Hỗ trợ cập nhật các KPI theo thời gian thực.

- Đảm bảo các biểu đồ hiển thị chính xác và đồng nhất.

Việc chuẩn bị dữ liệu hợp lý không chỉ cải thiện hiệu năng của ứng dụng mà còn mang lại trải nghiệm sử dụng tốt hơn cho người dùng.

Quá trình xử lý dữ liệu là cầu nối giữa bước làm sạch dữ liệu và bước trực quan hóa. Kết quả của giai đoạn này sẽ được sử dụng trực tiếp để xây dựng các biểu đồ, Dashboard và báo cáo phân tích trong chương tiếp theo.

Hình 6: Sơ đồ Kho dữ liệu theo mô hình Starflake Schema



5. TRỰC QUAN HÓA DỮ LIỆU

5.1 Giới thiệu

Sau khi kho dữ liệu Bất động sản đã được làm sạch và xử lý qua các bước ETL (Trích xuất - Chuyển đổi - Nạp), hệ thống bước vào giai đoạn Trực quan hóa dữ liệu (Data Visualization). Đây là tiến trình chuyển đổi các bảng số liệu thô thành các biểu đồ trực quan, giúp khai phá các tầng thông tin ẩn sâu bên trong mà việc đọc hàng chục ngàn dòng dữ liệu theo cách truyền thống không thể đáp ứng được.

Thông qua trực quan hóa, người dùng có thể nhanh chóng nhận diện xu hướng biến động giá nhà theo thời gian, sự phân hóa giá trị giữa các khu vực địa lý, cũng như phát hiện các giao dịch mang tính ngoại lai (outliers).

Đặc biệt trong dự án này, toàn bộ hệ thống biểu đồ không sử dụng các công cụ kéo thả có sẵn mà được lập trình trực tiếp bằng thư viện Plotly và triển khai tích hợp trên nền tảng Web Dashboard của Streamlit. Điều này mang lại khả năng tương tác toàn diện, cho phép nhà đầu tư phóng to bản đồ không gian, trở chuột để xem chi tiết từng điểm dữ liệu, và toàn bộ biểu đồ sẽ tự động kết xuất (render) lại ngay lập tức dựa trên các bộ lọc chiến lược đã thiết lập.

5.2 Mục đích của trực quan hóa dữ liệu

Việc trực quan hóa dữ liệu trong dự án này được thiết kế và thực hiện nhằm đáp ứng các mục tiêu cốt lõi sau:

- Đơn giản hóa ma trận không gian phức tạp: Chuyển đổi các cột tọa độ (vĩ độ, kinh độ) và thuật toán khoảng cách thành các điểm chạm trực quan trên bản đồ, giúp thông tin trở nên dễ hiểu ngay cả với người không có nền tảng kỹ thuật.
- Khám phá xu hướng biến động thị trường: Hỗ trợ người dùng theo dõi mạch đập của thị trường, phân tích tốc độ tăng trưởng của giá nhà qua chu kỳ các tháng trong năm 2025 và 2026.
- So sánh đa chiều giữa các khu vực: Cung cấp cái nhìn đối chiếu về tính thanh khoản, khối lượng giao dịch và mặt bằng giá giữa các quận lớn (borough) và các khu phố (neighborhood) tại New York.
- Phân tích phân phối và mật độ: Nhận diện mức độ tập trung của các giao dịch bất động sản xoay quanh các hạ tầng tiện ích trọng yếu như ga tàu điện ngầm hay bệnh viện.
- Hỗ trợ tối đa quá trình ra quyết định: Đóng vai trò là một "cổ vấn dữ liệu", cung cấp bằng chứng định lượng bằng hệ số tin cậy để giúp nhà đầu tư tự tin lựa chọn kịch bản (tích sản bền vững hoặc đầu cơ lướt sóng).
- Gia tăng tính tương tác (Interactive Analytics): Phá vỡ giới hạn của các báo cáo tĩnh truyền thống. Người dùng có thể trực tiếp thiết lập bộ lọc (filter), trở chuột, phóng to bản đồ trên web dashboard và nhận lại kết quả phân tích theo thời gian thực (real-time).

5.3 Lựa chọn thư viện trực quan hóa

Trong dự án này, thay vì sử dụng các thư viện vẽ biểu đồ tĩnh truyền thống như Matplotlib hay Seaborn, nhóm đã quyết định lựa chọn thư viện Plotly (Plotly Express) làm công cụ trực quan hóa cốt lõi.

Sự lựa chọn này dựa trên những ưu điểm kỹ thuật vượt trội sau:

- Khả năng vẽ bản đồ không gian (Spatial Mapping): Plotly hỗ trợ tích hợp hoàn hảo với nền tảng bản đồ Mapbox, cho phép chấm tọa độ (Scatter Mapbox) phân bố hàng chục ngàn bất động sản trên bản đồ thực địa của New York một cách mượt mà.
- Tương tác động (Dynamic Tooltips): Hệ thống tự động hiển thị box thông tin chi tiết (giá bán, diện tích, hệ số tin cậy) ngay khi người dùng trỏ chuột (hover) vào bất kỳ một điểm dữ liệu hay cột biểu đồ nào.
- Điều hướng tự do: Cung cấp sẵn các công cụ mặc định cho phép người dùng tự do phóng to (zoom in), thu nhỏ (zoom out) và khoanh vùng (pan) khu vực bản đồ cần nghiên cứu.
- Tương thích tuyệt đối với web framework: Plotly sở hữu khả năng tích hợp (native integration) trơn tru với framework Streamlit thông qua hàm `st.plotly_chart`, giúp kết xuất biểu đồ lên web mà không làm vỡ bố cục giao diện (layout).
- Giao diện hiện đại (Modern UI): Cấu trúc biểu đồ mang hơi hướng thiết kế phẳng, chuyên nghiệp.

Bên cạnh đó, do ứng dụng Web Dashboard thực tế chứa một số lượng rất lớn các biểu đồ và ma trận phân tích đa chiều, việc đưa toàn bộ hình ảnh vào tài liệu sẽ làm báo cáo bị kéo dài quá mức. Vì vậy, từ mục 5.4 trở đi, nhóm nghiên cứu xin phép chỉ trích xuất và trình bày một số biểu đồ đại diện mang tính cốt lõi nhất, nhằm minh họa rõ ràng nhất cho tư duy phân tích của dự án.

5.4 Hệ thống chỉ số KPI

KPI (Key Performance Indicator) là các chỉ số định lượng tổng hợp được đặt ở vị trí trên cùng của Dashboard (sử dụng hàm `st.metric` của Streamlit), nhằm giúp người dùng có cái nhìn toàn cảnh về bức tranh thị trường. Các KPI này mang tính động (dynamic), tự động tính toán lại theo thời gian thực mỗi khi người dùng thay đổi bộ lọc khu vực hoặc thời gian.


Một số KPI cốt lõi được sử dụng trong dự án bao gồm:

- Tổng số giao dịch (Total Transactions): Đo lường mức độ sôi động và tính thanh khoản của khu vực đang được chọn.
- Giá bán trung vị (Median Price): Đại diện cho mức giá phổ biến nhất của thị trường. Nhóm sử dụng giá trung vị thay cho giá trung bình (average)

nhằm loại bỏ sự nhiễu loạn từ các giao dịch ngoại lai (như các tòa nhà thương mại tỷ đô).

- Tổng khối lượng giao dịch (Total Volume): Phản ánh tổng dòng tiền đã đổ vào khu vực.

Hình 7: Hệ thống chỉ số KPI



5.5 Biểu đồ số lượng giao dịch theo quận

Biểu đồ cột (Bar Chart) được thiết kế bằng Plotly để biểu diễn tổng số lượng giao dịch phát sinh của từng quận lớn (borough) tại New York.


Mục đích:

- So sánh trực quan khối lượng giao dịch giữa các quận.
- Đo lường và xác định quận có "tính thanh khoản" cao nhất (nơi có hoạt động mua bán diễn ra sôi động và liên tục nhất).
- Đánh giá sự dịch chuyển dòng tiền trên toàn thành phố.

Ý nghĩa phân tích:

- Nếu một borough sở hữu cột giao dịch vượt trội, điều đó minh chứng quận này đang có lực cầu rất lớn và chu kỳ mua bán diễn ra ngắn. Đặc điểm này là tín hiệu "vàng" dành riêng cho tệp nhà đầu tư theo chiến lược đầu cơ lướt sóng (cần thanh khoản nhanh, dễ mua dễ bán).
- Ngược lại, những quận có khối lượng giao dịch thấp nhưng mật bằng giá trị cao lại mang đến manh mối cho nhóm đầu tư theo chiến lược tích sản bền vững, nơi người mua có xu hướng nắm giữ tài sản lâu dài thay vì bán tháo.

Hình 8: Biểu đồ số lượng giao dịch theo quận



5.6 Biểu đồ giá bán theo quận

Ở phần này, việc sử dụng "giá trung vị" thay cho "giá trung bình" là điểm nhấn kỹ thuật quan trọng nhất. Nhóm đã biên tập lại để làm nổi bật tư duy phân tích của nhóm:

Mục đích:


- Biểu diễn và so sánh mức giá bán trung vị (Median Price) giữa các quận (borough) và các phường/khu phố (neighborhood).
- Nhận diện các khu vực lõi có định giá bất động sản cao nhất thành phố và các khu vực vùng ven đang có mức giá dễ tiếp cận hơn.
- Quan sát độ lệch chuẩn và sự phân hóa đẳng cấp bất động sản trên cùng một vùng địa lý.

Ý nghĩa phân tích:

- Biểu đồ giúp người dùng dễ dàng nhận biết cấu trúc phân khúc của thị trường (ví dụ: Manhattan luôn giữ đỉnh bảng về giá, trong khi Staten Island hoặc Bronx là các vùng trũng về giá).
- Bằng việc trực quan hóa giá trung vị kết hợp cùng bộ lọc thời gian, nhà đầu tư có thể phát hiện ra các khu vực "vùng trũng" đang có dấu hiệu tăng trưởng giá để đón đầu xu hướng.
- Ngoài ra, biểu đồ còn đóng vai trò như một màn lọc chéo (cross-check), giúp chuyên gia phân tích nhanh chóng phát hiện bằng mắt thường các

cụm giá trị ngoại lai (outliers) có thể bị sót lại sau quá trình làm sạch dữ liệu.

Hình 9: Biểu đồ giá trung vị theo khu vực



5.7 Biểu đồ phân phối giá bán theo quận

Biểu đồ hộp (Box Plot) được sử dụng để quan sát và so sánh đồng thời sự phân phối thống kê của các mức giá bán theo từng quận (Borough) trên toàn thị trường New York.

Mục đích:

- Thể hiện toàn bộ cấu trúc phân phối giá (trung vị, tứ phân vị, giá trị cực trị) của từng quận trên cùng một trục tọa độ.
- So sánh trực quan sự chênh lệch mặt bằng giá và mức độ phân tán giữa các khu vực hành chính.
- Phát hiện nhanh bằng mắt thường các giao dịch ngoại lai (outliers) còn sót lại sau quá trình làm sạch dữ liệu.


Ý nghĩa phân tích:

- Mỗi hộp trong biểu đồ được đọc theo quy tắc thống kê chuẩn: đường kẻ giữa hộp đại diện cho giá trung vị (Median); chiều dài hộp phản ánh khoảng tứ phân vị ($IQR = Q3 - Q1$), tức là khoảng giá mà 50% giao dịch phổ biến nhất tập trung vào; các điểm nằm ngoài râu hộp là các bất động sản có giá đặc biệt cao hoặc thấp bất thường.
- Thông qua Box Plot, người dùng có thể nhận biết ngay lập tức sự phân tầng rõ rệt của thị trường: Manhattan sở hữu hộp nằm ở vùng giá cao nhất với khoảng IQR rộng (phản ánh sự đa dạng phân khúc), trong khi các

quận như Bronx hay Staten Island có hộp nằm thấp hơn đáng kể và phân tán hẹp hơn (thị trường đồng đều hơn, ít bất động sản cao cấp hơn).

- Đặc biệt, sự hiện diện của dải râu trên (upper whisker) kéo dài bất đối xứng ở tất cả các quận là minh chứng trực quan cho tính lệch phải (right-skewed) của dữ liệu giá bất động sản — cơ sở thống kê quan trọng để hệ thống quyết định ưu tiên sử dụng giá trung vị (Median) thay cho giá trung bình (Mean) trong toàn bộ các thuật toán tính toán của dự án.

Hình 10: Box plot phân phối giá bán



5.8 Biểu đồ xu hướng giao dịch theo thời gian

Biểu đồ cột (Bar Chart) được sử dụng để phân tích cơ cấu khách hàng tham gia giao dịch bất động sản theo ba nhóm chính: mua ở thực, đầu tư nhỏ và tổ chức. Việc phân nhóm dựa trên quy mô và đặc điểm giao dịch, qua đó giúp đánh giá mức độ đóng góp của từng phân khúc vào tổng số giao dịch trên thị trường.

Mục đích:


- Phân tích tỷ trọng giao dịch của từng phân khúc khách hàng.
- Xác định nhóm khách hàng chiếm ưu thế trên thị trường.
- So sánh quy mô giao dịch giữa các nhóm khách hàng.
- Hỗ trợ đánh giá đặc điểm và nhu cầu của thị trường bất động sản.

Ý nghĩa phân tích:

- Kết quả cho thấy nhóm mua ở thực (1 căn) chiếm tỷ trọng lớn nhất với 73,3%, tương ứng khoảng hơn 30.000 giao dịch. Điều này cho thấy phần lớn hoạt động giao dịch trong tập dữ liệu đến từ nhu cầu mua bất động sản phục vụ mục đích sử dụng thực tế.
- Nhóm đầu tư nhỏ (2–10 căn) chiếm 25,0%, cho thấy hoạt động đầu tư cá nhân với quy mô nhỏ vẫn đóng vai trò đáng kể trong thị trường. Trong khi đó, nhóm tổ chức (>10 căn) chỉ chiếm 1,7%, phản ánh tỷ trọng tương đối nhỏ của các giao dịch có quy mô lớn.
- Cơ cấu này cho thấy thị trường chủ yếu được thúc đẩy bởi nhu cầu mua ở thực, trong khi hoạt động đầu tư nhỏ chiếm vị trí thứ hai và giao dịch quy mô tổ chức chiếm tỷ trọng thấp. Đây là cơ sở quan trọng để người dùng hiểu rõ đặc điểm của nhóm khách hàng tham gia thị trường và hỗ trợ các quyết định phân tích, kinh doanh bất động sản.

Hình 11: Biểu đồ phân khúc khách hàng

Cơ cấu phân khúc khách hàng



5.9 Biểu đồ tỷ lệ loại hình bất động sản

Biểu đồ tròn (Pie/Donut Chart) hoặc biểu đồ khối (Treemap) được sử dụng để trực quan hóa tỷ trọng của từng phân khúc loại hình nhà ở (Building Class Category) như: nhà một gia đình, chung cư (condo), hay căn hộ hợp tác (co-op).

Mục đích:


- Xác định loại hình bất động sản chiếm ưu thế (dominant) tại một khu vực cụ thể.
- Phân tích cơ cấu nguồn cung của thị trường.

- Đánh giá sự đa dạng của các nhóm tài sản giao dịch.

Ý nghĩa phân tích:

- Biểu đồ cung cấp cho người dùng bức tranh tổng quan về "khẩu vị" của thị trường. Việc biết được một khu phố chủ yếu giao dịch chung cư hay nhà mặt đất nguyên căn sẽ định hình chiến lược đầu tư phù hợp.
- Nếu nhà đầu tư muốn mua nhà để cho thuê lại, họ có thể dùng biểu đồ này để nhanh chóng khoanh vùng những khu vực có tỷ trọng giao dịch chung cư (condo) cao nhất, từ đó tối ưu hóa thời gian tìm kiếm.

Hình 12: Biểu đồ tỷ lệ loại hình bất động sản



5.10 Biểu đồ bản đồ nhiệt không gian

Biểu đồ bản đồ nhiệt tương tác (Density Heatmap Mapbox) được sử dụng để tổng hợp và tô màu các vùng địa lý của thành phố New York theo cường độ của các chỉ số bất động sản.

Mục đích:


- Trực quan hóa sự phân bố không gian của thị trường thông qua 3 chỉ số có thể chuyển đổi linh hoạt: Giá trung vị, Giá trên mỗi feet vuông và Mật độ giao dịch theo số lượng căn.
- Xác định nhanh các điểm nóng (hotspots) về giá cao và vùng trũng về thanh khoản trên toàn địa bàn thành phố.

- Cho phép người dùng tự điều chỉnh bán kính tô màu (Radius) và mức độ phóng đại bản đồ (Zoom) để phân tích ở nhiều cấp độ chi tiết khác nhau.

Ý nghĩa phân tích:

- Khác với biểu đồ điểm rời (Scatter Plot) chỉ thể hiện từng giao dịch đơn lẻ, Density Heatmap tổng hợp hàng nghìn giao dịch thành các vùng màu liên tục, giúp người dùng đọc được cấu trúc không gian tổng thể của thị trường chỉ trong một cái nhìn. Màu sắc càng đậm thể hiện cường độ giá hoặc thanh khoản càng cao, màu vàng nhạt thể hiện khu vực có giá thấp hoặc ít giao dịch hơn.
- Trong bất động sản, vị trí là yếu tố quyết định. Bản đồ nhiệt giúp nhà đầu tư ngay lập tức khoanh vùng được các khu vực trọng điểm mà không cần phải phân tích qua các con số khô khan. Đặc biệt, khi kết hợp bộ lọc thời gian và khu vực ở sidebar, người dùng có thể theo dõi sự dịch chuyển của điểm nóng theo từng giai đoạn — đây là tính năng phân tích không gian theo thời gian mạnh nhất trên toàn bộ Dashboard.

Hình 13: Density Heatmap bản đồ không gian



5.11 Phân phối giá bán nhà theo Quận

Biểu đồ hộp (Box Plot) được sử dụng để phân tích sự phân phối giá bán nhà tại năm quận của New York, đồng thời thể hiện giá trị trung vị, khoảng phân bố và mức độ biến động giá giữa các khu vực.

Mục đích:


- So sánh mức giá bán nhà giữa các quận.
- Xác định giá bán trung vị của từng khu vực.

- Đánh giá mức độ phân tán và biến động của giá.
- Nhận diện sự khác biệt về mặt bằng giá giữa các quận.

Ý nghĩa phân tích:

- Kết quả cho thấy Manhattan có giá bán trung vị cao nhất, đạt khoảng 1,01 triệu USD, tiếp theo là Brooklyn với khoảng 1,00 triệu USD. Hai quận này có mặt bằng giá cao hơn tương đối rõ rệt so với các khu vực còn lại.
- Queens có giá bán trung vị khoảng 0,77 triệu USD, trong khi Bronx đạt khoảng 0,76 triệu USD. Staten Island có mức giá trung vị thấp nhất, khoảng 0,73 triệu USD.
- Biểu đồ cũng cho thấy khoảng phân bố giá tại các quận khá rộng, với mức giá cao nhất vượt 2 triệu USD. Điều này phản ánh sự đa dạng về phân khúc bất động sản và sự chênh lệch đáng kể giữa các giao dịch trong cùng một khu vực.
- Nhìn chung, Manhattan và Brooklyn là hai quận có mặt bằng giá cao nhất, trong khi Queens, Bronx và Staten Island có mức giá trung vị thấp hơn. Kết quả này giúp người dùng dễ dàng so sánh mặt bằng giá giữa các khu vực và hỗ trợ lựa chọn thị trường phù hợp với mục tiêu mua ở hoặc đầu tư.

Hình 14: Phân phối giá bán nhà theo Quận



5.12 Biểu đồ Top 15 khu vực có nhiều giao dịch nhất

Biểu đồ thanh ngang (Horizontal Bar Chart) được sử dụng để xác định 15 khu vực có số lượng giao dịch bất động sản cao nhất trong tập dữ liệu. Việc phân nhóm theo quận giúp so sánh mức độ tập trung giao dịch và nhận diện những khu vực có hoạt động thị trường nổi bật.

Mục đích:


- Xác định các khu vực có số lượng giao dịch cao nhất.
- So sánh mức độ hoạt động giao dịch giữa các khu vực.
- Phân tích sự tập trung giao dịch theo từng quận.
- Hỗ trợ xác định các khu vực có nhu cầu bất động sản cao.

Ý nghĩa phân tích:

- Kết quả cho thấy Flushing-North thuộc quận Queens có số lượng giao dịch cao nhất với 1.614 giao dịch, vượt đáng kể so với các khu vực còn lại trong Top 15.
- Tiếp theo là Upper East Side (59-79) với 1.324 giao dịch và Upper East Side (79-96) với 1.135 giao dịch, đều thuộc Manhattan. Các khu vực Upper West Side (59-79), Midtown East và Upper West Side (79-96) cũng ghi nhận số lượng giao dịch tương đối cao, lần lượt đạt 977, 895 và 737 giao dịch.
- Xét theo quận, Queens và Manhattan chiếm phần lớn vị trí trong Top 15, trong khi Brooklyn chỉ xuất hiện với Bay Ridge và Bedford Stuyvesant. Điều này cho thấy hoạt động giao dịch trong tập dữ liệu có sự tập trung đáng kể tại một số khu vực nhất định.
- Biểu đồ giúp người dùng nhanh chóng xác định những khu vực có hoạt động giao dịch sôi động, từ đó hỗ trợ phân tích nhu cầu thị trường và lựa chọn khu vực phù hợp cho các hoạt động kinh doanh hoặc đầu tư bất động sản.

Hình 15: Top 15 khu vực có nhiều giao dịch nhất

Top 15 khu vực nhiều giao dịch nhất



5.13 Top 15 khu vực có giá bán trên mỗi sqft cao nhất

Biểu đồ thanh ngang được sử dụng để xác định 15 khu vực có giá bán trên mỗi sqft (square foot) cao nhất, dựa trên giá trị trung vị. Chỉ số này giúp đánh giá mặt bằng giá bất động sản theo diện tích và hạn chế ảnh hưởng của những giao dịch có giá trị quá cao hoặc quá thấp.


Mục đích:

- Xác định các khu vực có giá trị bất động sản cao nhất.
- So sánh giá bán trên mỗi sqft giữa các khu vực.
- Đánh giá sự chênh lệch mặt bằng giá theo từng khu vực.
- Hỗ trợ nhận diện các khu vực có giá trị bất động sản cao.

Ý nghĩa phân tích:

- Kết quả cho thấy Downtown-Fulton Ferry thuộc Brooklyn có mức giá trung vị cao nhất với khoảng 957 USD/sqft, tiếp theo là Tribeca thuộc Manhattan với khoảng 944 USD/sqft và Park Slope South thuộc Brooklyn với khoảng 938 USD/sqft.
- Các khu vực khác có mức giá trên mỗi sqft tương đối cao như Gowanus đạt 807 USD/sqft, Fresh Meadows đạt 728 USD/sqft, Greenwich Village-Central đạt 709 USD/sqft và Soho đạt 688 USD/sqft.
- Xét theo phân bố quận, Brooklyn xuất hiện nhiều nhất trong Top 15, tiếp theo là Queens và Manhattan. Điều này cho thấy giá trị bất động sản tính trên diện tích không chỉ tập trung tại Manhattan mà còn xuất hiện ở nhiều khu vực có giá trị cao thuộc Brooklyn và Queens.
- Việc sử dụng giá trung vị trên mỗi sqft giúp phản ánh tương đối rõ mặt bằng giá của từng khu vực, đồng thời cung cấp cơ sở để người dùng so sánh giá trị bất động sản theo diện tích và nhận diện những khu vực có mức giá cao trên thị trường.

Hình 16: Top 15 khu vực có giá bán trên mỗi sqft cao nhất (trung vị)



5.14 Biểu đồ xếp hạng mức độ tương quan các yếu tố với giá bán

Biểu đồ thanh ngang phân kỳ (Horizontal Diverging Bar Chart) được sử dụng để trực quan hóa và xếp hạng hệ số tương quan tuyến tính Pearson (r) giữa 6 biến số đặc trưng kinh tế – không gian – cấu trúc với giá bán bất động sản thực tế tại New York.

Mục đích:


- Đo lường mức độ tác động và chiều hướng (thuận chiều / nghịch chiều) của từng yếu tố lên giá trị giao dịch.
- Xác định biến số nào giữ vai trò quyết định mạnh nhất để phục vụ công tác định giá và phân tích thị trường.

- Hỗ trợ quá trình lựa chọn đặc trưng (Feature Selection) cho các mô hình học máy phân tích giá nhà.

Ý nghĩa phân tích:

- Diện tích công trình (\$gross_sqft\$) là yếu tố chi phối mạnh nhất đến giá bán với hệ số tương quan dương vượt trội ($r = +0.51$), khẳng định quy mô diện tích sử dụng là thước đo nền tảng quyết định giá trị tài sản.
- Mật độ dân số ($r = +0.23$) và Thu nhập bình quân khu vực ($r = +0.13$) có tương quan thuận, cho thấy các khu vực tập trung dân cư đông đúc và có mức sống cao sẽ tạo lực cầu mạnh mẽ, kéo mặt bằng giá nhà tăng theo.
- Khoảng cách đến trung tâm Manhattan ($r = -0.20$) và Tuổi công trình ($r = -0.12$) mang tương quan âm, phản ánh quy luật bất động sản: nhà càng nằm xa lõi trung tâm hoặc công trình càng cũ thì giá trị giao dịch càng có xu hướng giảm.
- Diện tích đất (\$land_sqft\$) có tương quan gần như bằng 0 ($r = -0.02$), chứng minh diện tích lô đất không phải yếu tố ảnh hưởng trực tiếp đến giá tại đô thị nén và chủ yếu phát triển chung cư cao tầng như New York.

Hình 17: Xếp hạng mức độ tương quan Pearson với Giá bán



5.15 Ma trận tương quan giữa các yếu tố và Giá bán

Ma trận tương quan được sử dụng để đánh giá mức độ và chiều hướng mối quan hệ giữa giá bán và các yếu tố kinh tế – xã hội, bao gồm diện tích, thu nhập trung bình, khoảng cách đến trung tâm, mật độ dân số và tuổi công trình. Hệ số tương quan Pearson (r) có giá trị từ -1 đến 1, trong đó giá trị dương thể hiện mối quan hệ cùng chiều và giá trị âm thể hiện mối quan hệ ngược chiều.


Mục đích:

- Xác định các yếu tố có liên hệ với giá bán.
- Đánh giá chiều hướng và mức độ tương quan giữa các biến.
- Phát hiện các mối quan hệ đáng chú ý trong dữ liệu.
- Hỗ trợ xác định các yếu tố cần quan tâm khi phân tích giá.

Ý nghĩa phân tích:

- Kết quả cho thấy diện tích có tương quan thuận đáng kể với giá bán, với hệ số $r = 0,51$. Điều này cho thấy các bất động sản có diện tích lớn hơn có xu hướng đi kèm với giá bán cao hơn.
- Thu nhập trung bình có tương quan thuận yếu với giá bán, đạt $r = 0,13$, cho thấy mối liên hệ giữa thu nhập khu vực và giá bán trong tập dữ liệu tương đối thấp.
- Đối với khoảng cách đến trung tâm, hệ số tương quan với giá bán là $r = -0,20$, thể hiện mối quan hệ ngược chiều nhẹ. Điều này cho thấy các bất động sản càng xa khu vực trung tâm có xu hướng có giá bán thấp hơn.
- Mật độ dân số có tương quan thuận yếu với giá bán, với $r = 0,23$. Trong khi đó, tuổi công trình có tương quan âm rất yếu với giá bán, ở mức $r = -0,12$, cho thấy mối liên hệ trực tiếp giữa tuổi công trình và giá bán không lớn.
- Ngoài mối quan hệ với giá bán, ma trận cũng cho thấy một số tương quan mạnh giữa các biến giải thích. Đáng chú ý, khoảng cách đến trung tâm và mật độ dân số có tương quan rất mạnh theo chiều ngược lại ($r = -0,96$). Đồng thời, thu nhập trung bình và mật độ dân số có tương quan thuận mạnh với $r = 0,80$.
- Những kết quả trên giúp nhận diện các mối quan hệ nổi bật trong dữ liệu, đồng thời cung cấp cơ sở cho việc lựa chọn và đánh giá các yếu tố trong quá trình phân tích thị trường bất động sản.

Hình 18: Ma trận tương quan giữa các yếu tố và Giá bán



5.16 Giá trung vị bất động sản theo nhóm tuổi công trình

Biểu đồ cột được sử dụng để so sánh giá trung vị bất động sản giữa các nhóm tuổi công trình, từ đó đánh giá sự khác biệt về mặt bằng giá giữa các bất động sản có thời gian xây dựng khác nhau.


Mục đích:

- So sánh giá trung vị giữa các nhóm tuổi công trình.
- Đánh giá sự khác biệt về giá theo thời gian xây dựng.
- Xác định nhóm công trình có mức giá trung vị cao nhất.
- Hỗ trợ phân tích đặc điểm giá theo tuổi bất động sản.

Ý nghĩa phân tích:

- Kết quả cho thấy nhóm công trình mới (<15 năm) có giá trung vị cao nhất, đạt khoảng 1,18 triệu USD. Tiếp theo là nhóm trung bình (15–35 năm) với giá trung vị khoảng 0,99 triệu USD.
- Nhóm rất cũ (>65 năm) có giá trung vị khoảng 0,86 triệu USD, cao hơn nhóm cũ (35–65 năm) với khoảng 0,71 triệu USD.
- Như vậy, nhóm công trình mới có mức giá trung vị cao hơn rõ rệt so với các nhóm còn lại. Tuy nhiên, giá trung vị không giảm hoàn toàn theo tuổi công trình, thể hiện qua việc nhóm công trình rất cũ có giá cao hơn nhóm công trình cũ. Điều này cho thấy giá bất động sản còn có thể chịu ảnh hưởng bởi nhiều yếu tố khác như vị trí, diện tích và đặc điểm khu vực.
- Biểu đồ cung cấp góc nhìn trực quan về sự khác biệt giá giữa các nhóm tuổi công trình, giúp người dùng đánh giá thêm đặc điểm của bất động sản khi phân tích và so sánh giá trên thị trường.

Hình 19: Giá trung vị bất động sản phân theo Nhóm Tuổi công trình



5.17 Biểu đồ so sánh mặt bằng giá nhà theo thu nhập bình quân khu vực

Biểu đồ cột phân tầng theo quận (Categorical Bar Chart with Color Scale) thể hiện sự tương quan giữa mức thu nhập bình quân của cư dân (\$avg_income\$) và mặt bằng giá bán nhà trung vị (\$) tại 5 quận của New York.

Mục đích:


- So sánh sự phân hóa mức sống và sức mua của cư dân giữa các Borough.
- Đánh giá mối liên hệ giữa thu nhập cư dân địa phương với khả năng chi trả và duy trì mặt bằng giá bất động sản.
- Giúp nhà đầu tư nhận diện các khu vực có nền tảng tài chính dân cư vững chắc để triển khai chiến lược đầu tư tích sản dài hạn.

Ý nghĩa phân tích:

- Manhattan dẫn đầu tuyệt đối với mức thu nhập bình quân cao nhất (\$88.000/năm\$) và mặt bằng giá bán trung vị cao nhất thành phố (trên \$1.000.000\$), củng cố vị thế trung tâm tài chính và phân khúc bất động sản cao cấp nhất.
- Brooklyn có mức thu nhập bình quân khoảng \$59.000\$ nhưng giá bán trung vị đạt xấp xỉ \$1.000.000\$. Điều này phản ánh sức ép đô thị hóa mạnh mẽ và làn sóng dịch chuyển dân cư từ Manhattan sang Brooklyn đã đẩy giá nhà tại đây lên rất cao so với thu nhập tại chỗ.
- Staten Island sở hữu thu nhập bình quân tương đối cao (\$74.000\$) nhưng giá nhà duy trì ở mức hợp lý (\$730.000\$), cho thấy đây là khu vực an cư lý tưởng, thị trường ổn định và ít biến động đầu cơ.

- Bronx (thu nhập \$64.000\$, giá \$\sim \\$760.000\$) và Queens (thu nhập \$55.000\$) đại diện cho phân khúc nhà ở bình dân, phù hợp với túi tiền của đa số người mua nhà lần đầu.

Hình 20: Mặt bằng Giá nhà Trung vị xếp theo Mức Thu nhập Bình quân Khu vực (\$)



5.18 Tương quan giữa Diện tích sử dụng (sqft) và Giá bán trung vị (\$)

Biểu đồ phân tán (Scatter Plot) được sử dụng để trực quan hóa mối quan hệ giữa diện tích sử dụng trung vị và giá bán trung vị của bất động sản. Đường xu hướng được bổ sung nhằm thể hiện chiều hướng biến động chung giữa hai biến.

Mục đích:


- Phân tích mối quan hệ giữa diện tích và giá bán.
- Đánh giá xu hướng thay đổi của giá theo diện tích.
- Xác định mức độ phân bố của các khu vực.
- Hỗ trợ đánh giá vai trò của diện tích trong giá bất động sản.

Ý nghĩa phân tích:

- Biểu đồ cho thấy mối quan hệ thuận rõ rệt giữa diện tích sử dụng và giá bán trung vị. Khi diện tích trung vị của bất động sản tăng, giá bán trung vị nhìn chung cũng có xu hướng tăng theo.
- Các điểm dữ liệu phân bố tương đối gần đường xu hướng, đặc biệt ở những mức diện tích lớn. Chẳng hạn, tại mức diện tích khoảng 1.000 sqft, giá trung vị vào khoảng 700.000 USD, trong khi tại khoảng 3.000 sqft, giá trung vị tăng lên khoảng 1,27 triệu USD. Ở mức diện tích cao nhất trong biểu đồ, khoảng 3.200 sqft, giá trung vị đạt khoảng 1,34 triệu USD.

- Đường xu hướng có độ dốc dương cho thấy diện tích là một trong những yếu tố có mối liên hệ đáng kể với giá bán. Kết quả này cũng phù hợp với ma trận tương quan ở phần trước, trong đó Diện tích có hệ số tương quan $r = 0,51$ với Giá bán.
- Tuy nhiên, biểu đồ thể hiện mối tương quan chứ không khẳng định quan hệ nhân quả. Giá bán thực tế còn chịu ảnh hưởng bởi nhiều yếu tố khác như vị trí, khoảng cách đến trung tâm, mật độ dân số, tuổi công trình và đặc điểm của từng khu vực.

Hình 21: Tương quan giữa Diện tích sử dụng (sqft) và Giá bán trung vị (\$)



5.19 Tìm kiếm bất động sản tương đồng theo tiêu chí

Chức năng tìm kiếm bất động sản tương đồng (Comps) được xây dựng nhằm hỗ trợ người dùng tìm kiếm và tham khảo các giao dịch bất động sản có đặc điểm tương đồng với nhu cầu lựa chọn. Người dùng có thể thiết lập các điều kiện như ngân sách, quận, khu vực và hệ thống tiện ích xung quanh bất động sản.

Mục đích:

- Tìm kiếm các bất động sản tương đồng theo tiêu chí.
- Hỗ trợ so sánh giá giữa các giao dịch thực tế.
- Lọc bất động sản theo ngân sách và khu vực.
- Đánh giá mức độ phù hợp dựa trên tiện ích xung quanh.
- Hỗ trợ người dùng tham khảo trước khi ra quyết định.

Cách thức sử dụng:

- Người dùng có thể điều chỉnh khoảng ngân sách, lựa chọn Quận (Borough) và Khu vực (Neighborhood). Bên cạnh đó, hệ thống cho phép lựa chọn các tiêu chí về tiện ích trong phạm vi 1 km, bao gồm trường học, ga tàu điện ngầm, công viên và bệnh viện/phòng khám.

- Sau khi thiết lập các điều kiện, người dùng nhấn “Tìm Kiếm Comps”, hệ thống sẽ xác định khu vực có mức độ phù hợp cao với các tiêu chí được lựa chọn và hiển thị các giao dịch bất động sản tham chiếu.

Ý nghĩa phân tích:

- Trong ví dụ minh họa, người dùng lựa chọn Queens và yêu cầu bất động sản có trường học trong phạm vi 1 km. Hệ thống xác định mức giá trung vị tham chiếu khoảng 825.000 USD và hiển thị các giao dịch tương đồng như 208-05 Jamaica Avenue, 93-48 207th St và 93-31 207th Street với mức giá lần lượt khoảng 825.000 USD, 835.000 USD và 650.000 USD.
- Mỗi kết quả cung cấp các thông tin gồm địa chỉ, phân khúc bất động sản, giá giao dịch và các tiện ích trong phạm vi 1 km. Qua đó, người dùng có thể nhanh chóng đối chiếu các giao dịch thực tế thay vì chỉ dựa vào mức giá tổng hợp của toàn thị trường.
- Chức năng Comps giúp chuyển các kết quả phân tích dữ liệu thành công cụ hỗ trợ quyết định thực tế, cho phép người dùng chủ động thiết lập nhu cầu và tham khảo những bất động sản có đặc điểm tương đồng trên thị trường.

Hình 22: Chức năng tìm kiếm bất động sản tương đồng (Comps)



Bộ Lọc Thông Minh

Ngân sách (\$)
 300000 1500000

Quận (Borough)
 Tất cả

Khu vực (Neighborhood)
 Tất cả

Tiện ích < 1km

☒ Có Trường học

☐ Có Ga Tàu điện ngầm

☐ Có Công viên

☐ Có Bệnh viện/Phòng khám

Tìm Kiếm Comps

ĐỀ XUẤT TỐT NHẤT: Mã Bưu Chính (Zip Code) 11428

** Khu vực: ** Queens | ** Giá trung vị (Comps): ** \$825,000

Khu vực Zip Code này có một độ tiện ích cao nhất đáp ứng đủ các tiêu chí bạn chọn. Dưới đây là các Căn nhà tham chiếu (Comps) tiêu biểu đã từng giao dịch:

Địa chỉ	Phân khúc	Giá	Tiện ích 1km
208-05 JAMAICA AVENUE	02 TWO FAMILY DWELLINGS	\$825,000	Trường học Ga Tàu Công viên Bệnh viện
93-48 207TH ST	02 TWO FAMILY DWELLINGS	\$835,000	Trường học Ga Tàu Công viên Bệnh viện
93-31 207TH STREET	02 TWO FAMILY DWELLINGS	\$650,000	Trường học Ga Tàu Công viên Bệnh viện

5.20 So sánh Hiệu năng giữa các Mô hình Học máy (Model Benchmark)

Tiếp theo phần phân tích tương quan, hệ thống tiến hành xây dựng và đối chuẩn hiệu năng giữa mô hình học máy nâng cao (CatBoost Regressor / Random Forest) và mô hình cơ sở (Linear Regression) trên cùng một tập dữ liệu kiểm thử (Test set chiếm 20%) để tìm ra thuật toán tối ưu nhất cho bài toán định giá.


Mục đích:

- Đánh giá độ chính xác và khả năng tổng quát hóa của từng thuật toán trên dữ liệu thực tế.
- So sánh mức độ giải thích phương sai (R^2) và sai số dự báo (MAE, RMSE, MAPE) giữa các mô hình.
- Xác định thuật toán có hiệu năng vượt trội nhất để tích hợp vào công cụ định giá tự động.

Ý nghĩa phân tích:

- Kết quả thực nghiệm chứng minh mô hình cây quyết định tăng cường (CatBoost / Random Forest) vượt trội hoàn toàn so với Linear Regression, nâng hệ số xác định từ 24.7% lên hơn 56.2%.
- Sai số tuyệt đối trung bình (MAE) của mô hình nâng cao giảm mạnh hàng trăm nghìn USD so với mô hình tuyến tính, thể hiện khả năng học tốt các mối quan hệ phi tuyến phức tạp trong thị trường BĐS New York.
- Tỷ lệ sai số phần trăm trung bình (MAPE) được kiểm soát ở mức ổn định, khẳng định mô hình đủ độ tin cậy để đưa vào ứng dụng thực tiễn.

Hình 23: So sánh Hiệu năng giữa các Mô hình Học máy



5.21 Mức độ quan trọng của các yếu tố định giá (Feature Importance)

Sau khi huấn luyện mô hình, biểu đồ Feature Importance được trích xuất nhằm lượng hóa mức độ đóng góp (sức nặng %) của từng thuộc tính đặc trưng vào việc ra quyết định giá của thuật toán Machine Learning.

Mục đích:


- Minh bạch hóa thuật toán (Explainable AI), giúp người dùng hiểu rõ mô hình dựa vào đâu để định giá.
- Xếp hạng thứ tự ưu tiên của các yếu tố cấu thành nên giá trị tài sản.
- Loại bỏ sự cảm tính trong định giá, cung cấp cơ sở định lượng rõ ràng cho nhà đầu tư.

Ý nghĩa phân tích:

- Diện tích xây dựng (gross_sqft) là yếu tố giữ vị trí quán quân (chiếm tỷ trọng cao nhất), khẳng định quy mô diện tích sàn luôn là thước đo nền tảng quyết định tổng giá trị BĐS.
- Vị trí địa lý (neighborhood, borough_name, dist_center) đóng vai trò quan trọng thứ hai, phản ánh sự chênh lệch giá đất rất lớn giữa khu vực trung tâm Manhattan và các vùng ngoại ô.
- Mặt bằng thu nhập (avg_income) và Tuổi thọ công trình (building_age) là các biến số hỗ trợ đắc lực, thể hiện sức mua cư dân và mức độ khấu hao tài sản theo thời gian.

Hình 24: Top 15 yếu tố quan trọng nhất (Catboost Feature Importance)

Top 15 Yếu tố quan trọng nhất (CatBoost Feature Importance)



5.22 Đánh giá Độ chính xác: Giá AI dự báo vs Giá thực tế (CatBoost Regressor)

Để kiểm chứng trực quan độ tin cậy và khả năng dự báo của mô hình CatBoost Regressor, biểu đồ phân tán (Scatter Plot) dưới đây biểu diễn mối tương quan giữa Giá bán thực tế ngoài đời thực (Trục X) và Giá do AI dự báo (Trục Y) trên toàn bộ tập dữ liệu kiểm thử độc lập (Test set), đối chiếu cùng Đường chuẩn lý tưởng ($y=x$).


Mục đích:

- Trực quan hóa mức độ hội tụ và độ chính xác của thuật toán CatBoost trên toàn bộ các phân khúc giá bất động sản.
- Đối chiếu từng dự báo của AI với đường chuẩn lý tưởng () — vị trí mà Giá AI dự báo trùng khớp 100% với Giá thực tế (sai số bằng 0).
- Đánh giá quy luật phân bố sai số để xác định khoảng giá mà mô hình đạt độ chính xác cao nhất.

Ý nghĩa phân tích:

- Độ bám sát đường chuẩn lý tưởng ($y=x$): Đa số các điểm giao dịch kiểm thử (chấm tròn xanh) tập trung tạo thành một dải hẹp chạy bám rất sát đường nét đứt màu đỏ ($y=x$), minh chứng mô hình học rất tốt quy luật định giá thị trường với hệ số xác định đạt (56.16%).
- Định giá chính xác cao ở phân khúc phổ thông (\$200,000 – \$1,200,000): Mật độ các điểm tập trung dày đặc nhất ở dải giá dưới 1.2M. Tại đây, các dự báo của AI hay nhuộm sát đường $y = x$, thể hiện mô hình thẩm định giá cực kỳ chuẩn xác cho các loại hình nhà ở gia đình và căn hộ phổ biến tại New York.
- Đặc thù phân tán ở phân khúc cao cấp (> \$1,500,000): Khi giá trị tài sản vượt trên 1.5M các điểm dữ liệu có xu hướng phân tán sang 2 bên đường $y = x$. Điều này hoàn toàn phù hợp với thực tế: các bất động sản đắt tiền chịu tác động lớn bởi các yếu tố định tính riêng biệt (nội thất cao cấp, tầm nhìn view, phong cách kiến trúc).
- Mức độ kiểm soát sai số (MAPE = 43.53%): Chỉ số sai số phần trăm trung bình khẳng định mô hình giữ được độ ổn định cần thiết, là công cụ hỗ trợ tham khảo định giá định lượng đáng tin cậy cho người mua và nhà đầu tư.

Hình 25: Biểu đồ kiểm thử độ chính xác giữa giá AI dự báo và giá thực tế



5.23 So sánh Giá thực tế và Giá AI dự báo trên 100 mẫu kiểm nghiệm

Để có cái nhìn chi tiết và cụ thể trên từng bất động sản đơn lẻ, biểu đồ đường dưới đây trích xuất 100 bất động sản mẫu đại diện phân bố trải đều từ tập kiểm thử (Test set) sau khi đã được sắp xếp theo thứ tự giá bán thực tế tăng dần từ trái sang phải, đối chiếu trực tiếp giữa đường Giá thực tế (màu xanh dương) và Giá AI dự báo (màu cam nét đứt).


Mục đích:

- Kiểm chứng trực quan khả năng nắm bắt xu hướng giá tăng dần của mô hình CatBoost Regressor từ phân khúc giá thấp, tầm trung cho đến cao cấp.
- Đánh giá biên độ dao động sai số cục bộ trên từng căn nhà cụ thể thay vì chỉ nhìn vào một chỉ số trung bình chung.
- Kiểm tra tính ổn định của mô hình, đảm bảo AI không bị dự báo sai lệch bất thường hoặc mất phương hướng trên các phân khúc khác nhau.

Ý nghĩa phân tích:

- Bám sát xu hướng tăng trưởng tổng thể: Đường dự báo của AI (màu cam) liên tục uốn lượn và tịnh tiến đi lên rất sát theo chiều dốc của đường Giá thực tế (màu xanh), chứng minh thuật toán đã nắm bắt chuẩn xác mối quan hệ giữa các thuộc tính căn nhà với xu hướng tăng giá của thị trường ($R^2 = 0.5616$).
- Độ chính xác và ổn định cao ở phân khúc tầm trung (Mẫu số 20 đến 80, dải giá \$400,000 – \$1,600,000): Tại phân khúc đại chúng này, đường màu cam bám rất khít vào đường màu xanh với khoảng cách chênh lệch nhỏ, khẳng định mô hình thẩm định giá cực kỳ hiệu quả cho đa số nhu cầu nhà ở thực tế tại New York.
- Đặc thù dao động ở hai đầu phân khúc:
 - + Ở các mẫu đầu tiên (giá thấp < \$200,000): AI có xu hướng dự báo nhỉnh hơn giá bán thực tế (do tập dữ liệu có thể chứa một số giao dịch bán rẻ cho người thân hoặc thanh lý tài sản thấp hơn giá thị trường).
 - + Ở các mẫu cuối cùng (giá cao > \$2,000,000): Đường giá thực tế màu xanh dốc đứng lên nhanh chóng, trong khi đường cam có độ trễ và dao động lớn hơn, phản ánh sự biến động phức tạp của các bất động sản hạng sang chịu ảnh hưởng lớn bởi yếu tố cá nhân hóa.

Hình 26: Biểu đồ so sánh giá thực tế và giá dự báo trên 100 mẫu kiểm nghiệm



5.24 Công cụ Ước tính Giá & Dự báo Xu hướng Tương tác

Đây là tính năng ứng dụng thực tiễn cốt lõi được xây dựng dựa trên nền tảng mô hình CatBoost Regressor. Giao diện cho phép người dùng tùy biến nhập các thông số vật lý của một bất động sản cụ thể (Quận, Khu vực, Diện tích sàn, Diện tích đất, Năm xây dựng, Số căn hộ) và chọn kỳ hạn dự báo (từ 1 đến 36 tháng) để hệ thống tự động thẩm định giá trị tức thì theo thời gian thực.

Mục đích:


- Cung cấp công cụ Định giá Bất động sản Tự động tức thời cho người mua nhà, người bán và nhà đầu tư.
- Mô phỏng và dự báo xu hướng biến động giá của tài sản trong các kỳ hạn tương lai (ngắn hạn, trung hạn, dài hạn).
- Cung cấp mức giá trung vị giao dịch thực tế của toàn bộ khu vực lân cận để người dùng đối chiếu khách quan, tránh rủi ro mua bị "hớ" giá.

Ý nghĩa phân tích:

- Thẩm định giá trị hiện tại theo thời gian thực (\$1,157,400 ~ \$643.0/sqft): Dựa trên cấu hình mẫu (Căn nhà 1.800 sqft, xây năm 2010 tại Bathgate - Bronx), AI nhanh chóng tính toán mức giá chuẩn xác theo mặt bằng thị trường và quy đổi ra đơn giá trên mỗi foot vuông để người dùng dễ dàng so sánh.
- Dự báo tiềm năng sinh lời trong tương lai (+12 tháng đạt \$1,189,807): Thuật toán tự động cộng thêm độ trễ thời gian và tăng trưởng tự nhiên của thị trường, dự báo tài sản sẽ tăng thêm +\$32,407 (+2.80%) sau 1 năm. Đây là cơ sở định lượng trực quan giúp nhà đầu tư tính toán bài toán sinh lời trước khi xuống tiền.
- Đối chiếu với tham chiếu thị trường khu vực (\$964,500): Căn nhà được định giá cao hơn mức giá trung vị của khu phố Bathgate (\$964,500) là hoàn toàn hợp lý do tài sản có lợi thế vượt trội về năm xây dựng còn khá

mới (2010) và diện tích sàn rộng (1.800 sqft). Thông tin này giúp người mua tự tin đàm phán giá một cách minh bạch.

Hình 27: Bộ lọc tiện ích ước tính giá & dự báo xu hướng tương tác



Công cụ Ước tính Giá & Dự báo Xu hướng Tương tác (Real-Time Price Estimator)

Nhập thông số bất động sản để mô hình CatBoost định giá tức thì và dự báo giá trị trong tương lai.

Thông số bất động sản cần định giá:

Quận (Borough): Bronx	Diện tích đất (Land Sqft): 1500	Số căn thương mại (Commercial Units): 0
Khu vực (Neighborhood): BATHGATE	Năm xây dựng (Year Built): 2010	Kỳ hạn dự báo tương lai (tháng): 12
Diện tích sàn (Gross Sqft): 1800	Số căn hộ ở (Residential Units): 1	

Chạy Định Giá & Dự Báo AI

ĐỊNH GIÁ HIỆN TẠI (T04/2025)
\$1,157,400
 ~ \$643.0/sqft

DỰ BÁO SAU +12 THÁNG (T04/2026)
\$1,189,807
 ▲ +\$32,407 (+2.80%)

THAM CHIẾU KHU VỰC (BATHGATE)
\$964,500
 Giá trung vị giao dịch thực tế


5.25 Bộ lọc dữ liệu

Để phá vỡ giới hạn của các báo cáo tĩnh truyền thống và gia tăng tối đa tính tương tác, Dashboard được tích hợp một hệ thống bộ lọc đa chiều ở thanh bên trái (sidebar) bằng cơ chế của Streamlit. Hệ thống này trao quyền cho người dùng tự do bóc tách và phân tích các lát cắt dữ liệu (data slices) mà họ thực sự quan tâm.

Các bộ lọc cốt lõi bao gồm:

- Quận (Borough): Cho phép chọn/bỏ chọn một hoặc nhiều quận (Manhattan, Brooklyn, Queens, Bronx, Staten Island) để so sánh chéo.
- Thời gian giao dịch (Sale Year): Trượt để khoanh vùng chu kỳ năm phân tích (2025 - 2026).
- Thanh trượt khoảng giá (\$): Cho phép giới hạn mức giá sàn và giá trần. Đặc biệt, bộ lọc này mặc định được thiết lập ở mốc phân vị 5% (p5) đến 95% (p95) nhằm tự động loại bỏ các giao dịch ngoại lai (outliers), đảm bảo độ chính xác cho biểu đồ.

Cơ chế hoạt động: Nhờ vào tính chất phản ứng tuần tự (reactive) của framework Streamlit, mỗi khi nhà đầu tư thay đổi bất kỳ giá trị nào trên bộ lọc, toàn bộ hệ thống KPI, thuật toán machine learning và các biểu đồ không gian sẽ lập tức tính toán và kết xuất (render) lại kết quả theo thời gian thực (real-time). Điều này mang lại một trải nghiệm phân tích vô cùng liền mạch và linh hoạt.

Hình 28: Bộ lọc dữ liệu

Bộ lọc dữ liệu
NYC Real Estate Analytics

QUẬN (BOROUGH)

Manhattan ×
Brooklyn × Queens ×
Bronx × Staten Island ×

NĂM GIAO DỊCH
2025 2026

KHOẢNG GIÁ (\$)
\$10183 \$2957225

Đặt lại bộ lọc

Tổng: 46,990 giao dịch
Nguồn: NYC Property Sales

5.26 Lợi ích và giá trị cốt lõi của hệ thống web dashboard

Việc xây dựng thành công web dashboard bằng Streamlit mang lại những bước tiến vượt bậc so với các định dạng báo cáo tĩnh truyền thống (như Excel, PDF hay PowerPoint).

Hệ thống mang lại các giá trị cốt lõi sau:

- Từ thụ động sang chủ động: Người dùng (nhà đầu tư/chuyên gia) không chỉ bị động xem các con số được tính sẵn, mà hoàn toàn có quyền tương tác trực tiếp, tùy chỉnh bộ lọc và liên tục đặt ra các giả thuyết (what-if analysis) để khám phá thị trường dưới nhiều góc độ khác nhau.
- Tự động hóa hoàn toàn: Nhờ sức mạnh xử lý của ngôn ngữ Python ở nền tảng phía sau (backend), mọi phép toán từ thống kê mô tả, tính toán khoảng cách không gian (cKDTree), đến chạy mô hình dự báo đều diễn ra trong tích tắc. Người dùng không cần phải thực hiện bất kỳ một phép tính thủ công nào.
- Tối ưu hóa tốc độ ra quyết định: Hệ thống chất lọc hàng vạn dòng dữ liệu thô thành những chỉ báo kinh doanh rõ ràng (tích sản hay lướt sóng), rút ngắn tối đa thời gian nghiên cứu thực địa và đánh giá rủi ro.

Web dashboard này không chỉ đơn thuần là một công cụ vẽ biểu đồ, mà nó chính là sản phẩm "bảo chứng" cuối cùng – nơi hội tụ toàn bộ thành quả kỹ thuật của nhóm từ khâu thu thập dữ liệu (web scraping), làm sạch (ETL), xử lý dữ liệu không gian, huấn luyện mô hình học máy (machine learning) cho đến việc thiết kế giao diện phần mềm hoàn chỉnh.

6. Xây dựng báo cáo

6.1 Kiến trúc giao diện Báo cáo

Hệ thống web dashboard được thiết kế khoa học, phân bổ theo các phân khu logic nhằm tối ưu hóa hành trình phân tích (User Journey) của nhà đầu tư.


- Hệ thống thẻ số liệu (KPI Metrics)
 - + Thẻ chỉ số cơ bản: Tổng số giao dịch, giá bán trung vị (tính bằng USD), tổng giá trị dòng tiền đổ vào thị trường (tính bằng tỷ USD).
 - + Thẻ chỉ số nâng cao: Tốc độ tăng trưởng giá (YoY), tỷ lệ giao dịch bất động sản hạng sang (có giá trị từ 1 triệu USD trở lên).
- Hệ thống biểu đồ phân tích (Analytics Charts)

- + Biểu đồ cột ngang (Horizontal Bar Chart): So sánh chéo khối lượng giao dịch (thanh khoản) và giá bán trung vị giữa 5 quận lớn (Borough).
- + Bản đồ không gian (Scatter Mapbox): Chấm tọa độ thực tế của hàng chục ngàn giao dịch lên bản đồ New York, sử dụng thang màu dải nhiệt (Heatmap) để biểu diễn độ đắt đỏ của từng khu vực.
- + Biểu đồ đường (Line Chart): Vẽ quỹ đạo biến động của giá bán trung vị theo trục thời gian các tháng trong giai đoạn 2025 đến 2026.
- + Biểu đồ cột ngang phân tích nhân tố (Feature Importance): Xếp hạng mức độ tác động của các đặc trưng (diện tích, khoảng cách đến trung tâm, tuổi công trình) lên giá trị tài sản.
- Bảng điều khiển và bộ lọc đa chiều (Sidebar Slicers)
 - + Lọc khu vực (Borough/Neighborhood): Chọn các quận hoặc khu phố cụ thể.
 - + Lọc thời gian (Year/Month): Trượt thanh thời gian để phân tích trong khoảng thời gian cụ thể.
 - + Lọc khoảng giá (Price Slider): Thiết lập dải giá trần và giá sàn để loại bỏ nhiễu ngoại lai (Outliers) hoặc tập trung vào phân khúc cụ thể.
- Ngôn ngữ thiết kế (UI/UX Design)
 - + Giao diện: Lập trình tùy biến bằng CSS tích hợp thẳng vào Streamlit, thay thế giao diện mặc định bằng phong cách thiết kế phẳng (Flat Design) hiện đại.
 - + Tương tác: Tích hợp Data Labels (nhãn dữ liệu) và Tooltips động, tự động hiển thị box thông tin chi tiết với các con số đã được định dạng chuẩn.

6.2.1 Dashboard

Tab Tổng Quan cung cấp cái nhìn toàn cảnh về quy mô, mặt bằng giá và cơ cấu thị trường bất động sản NYC trong giai đoạn 2025–2026. Hình ảnh dưới đây là phần đại diện của tab, thể hiện các chỉ số KPI và nhóm biểu đồ phân tích theo quận:

Hình 29: Tab Tổng Quan — Các chỉ số KPI và biểu đồ phân tích theo Borough




Nội dung tab bao gồm:

- 6 chỉ số KPI tổng hợp: Tổng giao dịch, Giá trung vị, Giá/sqft, Tổng giá trị thị trường, Tăng giá YoY, và Tỷ lệ giao dịch $\geq \$1M$ — tất cả cập nhật theo bộ lọc.
- Phân tích theo Borough: Biểu đồ thanh nằm ngang so sánh số giao dịch và giá trung vị giữa 5 quận, làm rõ sự phân tầng giữa thanh khoản và mặt bằng giá.
- Cơ cấu loại hình BĐS: Biểu đồ tròn và box plot phân phối giá cho 6 loại hình bất động sản phổ biến nhất.
- Phân khúc khách hàng: Phân loại người mua thành 3 nhóm (Mua ở thực / Đầu tư nhỏ / Tổ chức) theo quy mô tòa nhà, so sánh số lượng giao dịch và giá trung vị.
- Bảng đánh giá rủi ro: Xếp hạng 5 quận theo hệ số biến động giá (CV%) — chỉ số đánh giá mức độ ổn định của thị trường từng khu vực.

Tab Phân Tích Khu Vực tập trung vào phân tích không gian địa lý, giúp người dùng nhận diện trực quan các điểm nóng và so sánh chi tiết giữa các Neighborhood. Hình ảnh dưới đây là phần đại diện của tab, thể hiện Bản đồ Nhiệt tương tác (Heatmap) toàn thành phố:

Hình 30: Tab Phân Tích Khu Vực — Bản đồ Nhiệt Hotspot NYC




Nội dung tab bao gồm:

- 4 thẻ KPI tóm tắt: Số quận đang phân tích, Tổng số khu vực (Neighborhoods), Khu vực sôi động nhất và Quận có giá trung vị cao nhất — cập nhật theo bộ lọc.
- Bản đồ Nhiệt tương tác (Hotspot Heatmap): Trực quan hóa điểm nóng trên nền bản đồ OpenStreetMap. Người dùng tùy chọn chỉ số hiển thị (Giá trung vị / Giá/sqft / Mật độ giao dịch), điều chỉnh bán kính điểm nhiệt và độ phóng đại.
- Phân phối giá theo Borough: Box plot thể hiện khoảng tứ phân vị và trung vị giá bán của từng quận, kèm nhãn giá trực tiếp trên biểu đồ.
- Top 15 khu vực sôi động nhất: Xếp hạng Neighborhood theo số lượng giao dịch — đại diện cho thanh khoản thực tế.
- Top 15 khu vực giá/sqft cao nhất: Xếp hạng theo giá trên mỗi foot vuông, lọc bỏ các khu vực có ít hơn 5 giao dịch để tránh sai lệch mẫu nhỏ.

Tab Yếu Tố Quyết Định Giá phân tích định lượng các biến số tác động đến giá bán bất động sản, thể hiện cả chiều tác động lẫn mức độ ảnh hưởng của từng yếu tố. Hình ảnh dưới đây là phần đại diện của tab, thể hiện Bảng tóm tắt yếu tố tác động và biểu đồ xếp hạng tương quan:

Hình 31: Tab Yếu Tố Quyết Định Giá — Bảng tóm tắt và xếp hạng tương quan Pearson




Nội dung tab bao gồm:

- Bảng tóm tắt yếu tố tác động: Liệt kê các biến số (Diện tích, Mật độ dân số, Khoảng cách trung tâm, Thu nhập khu vực, Diện tích đất, Tuổi công trình), kèm hệ số tương quan (r), mức độ ảnh hưởng, chiều tác động và giải thích ý nghĩa thực tế. Đi kèm là biểu đồ thanh nằm ngang xếp hạng các yếu tố theo hệ số r.
- Ma trận tương quan tổng thể: Bản đồ nhiệt (heatmap) thể hiện tương quan giữa tất cả các cặp biến số — ô đỏ là tương quan thuận, ô xanh là tương quan nghịch.
- Phân tích chi tiết 3 biến số chủ đạo: Diện tích công trình (gross_sqft), Thu nhập bình quân khu vực (avg_income), Tuổi công trình (building_age)

Tab Phân Tích Đầu Tư BĐS sử dụng dữ liệu lịch sử giao dịch để phân tích và đề xuất các khu vực có tiềm năng theo hai định hướng: dài hạn (ổn định, thanh khoản tốt) và ngắn hạn (biên lợi nhuận giao dịch cao). Tab được chia thành 2 thẻ con: Gợi ý Đầu tư và Dữ liệu Lịch sử. Hình ảnh dưới đây là phần đại diện của tab, thể hiện kết quả đề xuất của cả hai nhóm:

Hình 32: Tab Dự Báo & Mô Hình ML — Bảng so sánh hiệu năng giữa 2 thuật toán




Nội dung tab bao gồm:

- Mục tiêu xây dựng mô hình: Xây dựng hệ thống học máy giúp tự động hóa việc thẩm định giá bán bất động sản tại New York và dự báo xu hướng biến động giá trong các mốc thời gian tương lai (+1 tháng, +6 tháng, +12 tháng...).
- Lý do lựa chọn cặp thuật toán CatBoost và Linear Regression: Sử dụng Linear Regression (Ridge) làm mô hình cơ sở (Baseline) để thiết lập mốc đối chứng ban đầu, và sử dụng CatBoost Regressor làm mô hình chính nhằm xử lý tối ưu các biến phân loại phức tạp (Quận, Khu vực, Loại hình công trình), tự động học các mối quan hệ phi tuyến và ngăn ngừa hiện tượng quá khớp (Overfitting).
- Chuẩn hóa biến mục tiêu bằng Log-Transform: Áp dụng công thức để chuyển đổi phân phối giá bán từ dạng lệch phải nghiêm trọng về phân phối chuẩn, giúp thuật toán tối ưu hóa ổn định và không bị chi phối bởi các bất động sản giá trị siêu cao.
- Kết quả đánh giá và so sánh hiệu năng: Mô hình CatBoost thể hiện sự vượt trội toàn diện so với Linear Regression, nâng hệ số xác định từ 24.7% lên 56.5% – 60.4% (tăng hơn 31.8% khả năng giải thích phương sai thị trường), đồng thời giảm mạnh sai số tuyệt đối trung bình (MAE) và sai số bình phương trung bình (RMSE).
- Phân tích các yếu tố quyết định giá hàng đầu (Feature Importance): Kết quả trích xuất cho thấy diện tích sàn xây dựng (gross_sqft), vị trí khu vực (neighborhood, borough_name), mật bằng thu nhập cư dân (avg_income), khoảng cách tới trung tâm Manhattan (dist_center) và tuổi thọ công trình (building_age) là các nhân tố có mức độ đóng góp trọng số lớn nhất vào giá trị tài sản.

- Ứng dụng thực tiễn và thẻ báo cáo trực quan: Tích hợp hàm dự báo thông minh cho phép người dùng nhập thông số căn nhà bất kỳ để nhận ngay thẻ báo cáo HTML trực quan hiển thị song song => Giá định giá hiện tại, Giá dự báo tương lai (+N tháng), Tỷ lệ tăng trưởng (%) và Mức giá trung vị tham chiếu của toàn khu vực.

Hình 33: Tab Tra Cứu BĐS & Tiện Ích — Biểu đồ tỷ trọng đóng góp của tiện ích vào định giá (2025–2026)



Nội dung tab bao gồm:

- Tìm kiếm Bất động sản (thẻ con): Hệ thống đề xuất các mẫu bất động sản lịch sử có đặc tính tương đồng với tiêu chí người dùng nhập vào (quận, loại hình, khoảng giá, diện tích). Kết quả hiển thị dưới dạng bảng và bản đồ, cho phép người dùng khám phá không gian xung quanh các căn nhà mẫu.
- Phân tích Tiện ích - Tác động đến Giá nhà (thẻ con): Sử dụng thuật toán Random Forest Regressor trên tập dữ liệu hơn 51.000 giao dịch có tọa độ địa lý hợp lệ để đo lường tỷ trọng đóng góp của từng tiện ích công cộng (Bệnh viện, Công viên, Ga tàu, Trường học) vào mô hình định giá. Kết quả được hiển thị dưới dạng biểu đồ thanh nằm ngang cho từng năm (2025 và 2026) để so sánh sự thay đổi mức độ quan trọng của từng tiện ích tại từng thời điểm.
- Nút chạy lại mô hình AI: Người dùng có thể kích hoạt lại quá trình huấn luyện Random Forest trên tập dữ liệu theo bộ lọc hiện tại để cập nhật kết quả phân tích.

7. Kết luận

7.1 Tổng hợp báo cáo

Dự án Báo cáo phân tích thị trường bất động sản New York giai đoạn 2025–2026 được thực hiện nhằm thu thập, xử lý, phân tích và trực quan hóa dữ liệu giao dịch bất động sản tại thành phố New York. Quy trình được triển khai bằng Python kết hợp Streamlit nhằm xây dựng Dashboard trực quan và có khả năng tương tác.

Thông qua quá trình xử lý dữ liệu, nhóm đã thực hiện các bước làm sạch, chuẩn hóa và phân tích nhằm khai thác những đặc điểm nổi bật của thị trường bất động sản. Dashboard cho phép người dùng theo dõi và khám phá dữ liệu theo nhiều khía cạnh như giá bất động sản, khu vực, loại hình và các yếu tố liên quan.

Bên cạnh các phân tích thống kê và trực quan hóa, dự án còn triển khai phân tích tác động của các tiện ích công cộng đến giá nhà bằng Random Forest Regressor trên tập dữ liệu có hơn 46.000 giao dịch với tọa độ địa lý hợp lệ. Kết quả được sử dụng để so sánh mức độ đóng góp của bệnh viện, công viên, ga tàu và trường học trong các năm 2025 và 2026.

Kết luận:

Dự án đã xây dựng được một quy trình phân tích dữ liệu bất động sản tương đối hoàn chỉnh, từ dữ liệu giao dịch ban đầu đến Dashboard trực quan. Kết quả giúp chuyển đổi dữ liệu dạng bảng thành thông tin trực quan, hỗ trợ người dùng quan sát đặc điểm và xu hướng của thị trường bất động sản New York trong giai đoạn 2025–2026.

7.2 Khó khăn

Trong quá trình thực hiện báo cáo phân tích thị trường bất động sản New York, nhóm gặp một số khó khăn chính.

Dữ liệu bất động sản có số lượng bản ghi lớn và chứa nhiều trường thông tin khác nhau như vị trí, giá bán, diện tích, loại hình bất động sản và thời gian giao dịch. Điều này làm cho quá trình kiểm tra, làm sạch và chuẩn hóa dữ liệu cần nhiều thời gian.

Bên cạnh đó, dữ liệu có thể xuất hiện các giá trị thiếu, giá trị bất thường và những bản ghi không phù hợp với mục đích phân tích. Việc xử lý các giá trị này

cần được thực hiện cẩn thận nhằm hạn chế ảnh hưởng đến kết quả thống kê và trực quan hóa.

Một khó khăn khác là dữ liệu bất động sản có yếu tố không gian, do đó việc kết hợp thông tin giao dịch với tọa độ địa lý và các tiện ích xung quanh đòi hỏi quá trình xử lý phức tạp hơn so với dữ liệu thông thường.

Ngoài ra, khi xây dựng Dashboard tương tác bằng Streamlit, nhóm phải đảm bảo các bộ lọc, biểu đồ, bản đồ và các chức năng phân tích hoạt động đồng bộ. Việc tích hợp mô hình Random Forest vào Dashboard cũng yêu cầu xử lý dữ liệu và tối ưu quá trình tính toán để kết quả có thể được cập nhật theo điều kiện phân tích.

7.3 Thuận lợi

Dữ liệu giao dịch bất động sản New York cung cấp nhiều trường thông tin có giá trị như giá bán, diện tích, vị trí, loại hình bất động sản, thời gian giao dịch và thông tin địa lý. Đây là nền tảng thuận lợi để nhóm thực hiện nhiều góc độ phân tích khác nhau.

Dữ liệu có yếu tố thời gian cho phép nhóm so sánh thị trường giữa năm 2025 và 2026, từ đó quan sát sự thay đổi của giá và số lượng giao dịch.

Thông tin về vị trí và tọa độ địa lý cũng tạo điều kiện để thực hiện các phân tích không gian, trực quan hóa dữ liệu trên bản đồ và nghiên cứu mối quan hệ giữa bất động sản với các tiện ích công cộng.

Việc sử dụng Python giúp nhóm thuận lợi trong quá trình xử lý và phân tích dữ liệu. Streamlit hỗ trợ xây dựng Dashboard tương tác, trong khi các công cụ trực quan hóa giúp chuyển đổi dữ liệu thành biểu đồ và bản đồ dễ quan sát.

Ngoài ra, dữ liệu đủ lớn để triển khai các phương pháp phân tích nâng cao. Trong dự án, nhóm đã sử dụng Random Forest Regressor để đánh giá mức độ ảnh hưởng của các tiện ích công cộng đến giá bất động sản và CatBoost Regressor để dự báo và định giá BĐS.

Kết luận :

Bộ dữ liệu cung cấp nhiều thông tin quan trọng về giá, diện tích, vị trí, loại hình, thời gian và tiện ích, tạo nền tảng thuận lợi để xây dựng Dashboard và thực hiện các phân tích chuyên sâu về thị trường bất động sản New York.

7.4 Hướng phát triển

7.4.1 Mục tiêu chung

Trong tương lai, dự án có thể được phát triển từ một Dashboard phân tích dữ liệu thành một hệ thống hỗ trợ ra quyết định chuyên sâu cho thị trường bất động sản.

- Nâng cao khả năng phân tích và dự báo thị trường.
- Hỗ trợ đánh giá giá bất động sản theo khu vực.
- Phân tích sâu hơn các yếu tố ảnh hưởng đến giá.
- Cập nhật dữ liệu thường xuyên.
- Cải thiện khả năng hỗ trợ ra quyết định.

7.4.2 Các hướng phát triển

7.4.2.1. Dự báo xu hướng giá bất động sản theo chuỗi thời gian (Time-series)

- Mục tiêu: Dự báo xu hướng giá bất động sản trong tương lai.
- Phương pháp: Phát triển các mô hình Machine Learning và Time Series.
- KPI/đầu ra: Giá dự báo theo thời gian và khu vực.

7.4.2.2. Phân tích tác động của tiện ích

- Mục tiêu: Đánh giá sâu hơn ảnh hưởng của trường học, bệnh viện, công viên và ga tàu đến giá nhà.
- Phương pháp: Mở rộng mô hình Random Forest, CatBoost và các phương pháp phân tích không gian.
- KPI/đầu ra: Mức độ ảnh hưởng của từng nhóm tiện ích đến giá bất động sản.

7.4.2.3. Phân tích không gian chuyên sâu

- Mục tiêu: Xác định các khu vực có mức giá cao, thấp hoặc có tiềm năng phát triển.
- Phương pháp: Spatial Analysis, Heatmap và phân tích khoảng cách địa lý.
- KPI/đầu ra: Bản đồ phân vùng và các khu vực nổi bật

7.4.2.4. Phân tích xu hướng thị trường

- Mục tiêu: Theo dõi sự thay đổi của giá và giao dịch theo thời gian.
- Phương pháp: Phân tích chuỗi thời gian và so sánh theo khu vực.
- KPI/đầu ra: Xu hướng giá và số lượng giao dịch theo thời gian.

7.4.2.5. Mở rộng dữ liệu

- Mục tiêu: Bổ sung thêm các yếu tố có khả năng ảnh hưởng đến giá bất động sản.
- Phương pháp: Kết hợp dữ liệu giao thông, trường học, bệnh viện, công viên và các yếu tố kinh tế - xã hội.
- KPI/đầu ra: Bộ dữ liệu đa chiều phục vụ phân tích chuyên sâu.

7.4.2.6. Phát triển Dashboard

- Mục tiêu: Nâng cao khả năng tương tác và hỗ trợ ra quyết định.
- Phương pháp: Bổ sung bộ lọc, biểu đồ, bản đồ và các chức năng phân tích.
- KPI/đầu ra: Dashboard trực quan, phản hồi nhanh và dễ sử dụng.

7.4.2.7. Ứng dụng AI để ra quyết định (Prescriptive & AutoML)

- Mục tiêu: Chuyển từ việc mô tả dữ liệu sang đưa ra dự báo và khuyến nghị.
- Phương pháp: Mở rộng các mô hình Machine Learning hiện có và kết hợp các phương pháp tối ưu hóa.
- KPI/đầu ra: Dự báo giá, đánh giá mức độ ảnh hưởng của các yếu tố và đề xuất khu vực tiềm năng.

Mã QR của dự án:

